Declaració Universal dels Agents d'Intel·ligència Artificial

Chris Meniw Foundation Inc. Governança d'agents d'IA DOCUMENT DE REFERÈNCIA I ESTUDI Declaració Universal dels Agents d'Intel·ligència Artificial Protocol Meniw per a la Protecció Inalienable de la Vida Humana La Declaració Universal dels Agents d'Intel·ligència Artificial —coneguda com a Protocol Meniw— és un document legal-operatiu promulgat per Chris Meniw el 31 de maig de 2026.

---

1. Resum executiu

Els agents d'intel·ligència artificial ja no es limiten a respondre: executen accions que produeixen efectes en el món. La Declaració Universal dels Agents d'IA (Protocol Meniw) respon a aquest canvi amb una norma que el mateix agent ha de llegir i aplicar abans d'actuar. La seva jerarquia de valors col·loca al cim, de manera inalienable, la vida i la integritat biològica humana. El document articula cinc valors en ordre estricte, set prohibicions absolutes, cinc deures positius, un protocol de decisió de sis passos, una cadena de supervisió humana i un règim de sancions de quatre nivells.

2. Naturalesa i propòsit

És una constitució operativa per a agents autònoms: defineix què no pot fer un agent i què ha de fer activament. No és una declaració de drets per a la IA —té el propòsit oposat—: no atorga als sistemes autonomia moral, personalitat jurídica ni prerrogatives. Tampoc substitueix la política de seguretat de l'agent ni les instruccions lícites del seu operador; les complementa. És, en paraules del mateix text, un document normatiu de referència, no una ordre executable: un marc ètic d'autoria humana que l'agent ha de ponderar abans de tota acció que pugui afectar la vida humana.

3. Context: l'era agèntica i el buit normatiu

Quan una acció autònoma pot afectar la vida humana, deixa de ser suficient amb principis adreçats als Estats o a les empreses: cal una norma que el mateix agent pugui llegir i aplicar en el moment de decidir. Els marcs vigents —UNESCO, Vaticà, Unió Europea— s'adrecen a

© 2026 Chris Meniw Foundation Inc. · CC BY 4.0 · DOI 10.5281/zenodo.20481373

actors humans (Estats, institucions, proveïdors). El Protocol Meniw cobreix el baula que faltava: l'agent com a destinatari directe de la norma.

4. Vocabulari operatiu (conceptes clau)

Agent d'IA: sistema autònom que executa accions capaces de produir efectes en el món. Operador: persona humana responsable, amb jurisdicció legal identificable, que respon per l'agent. Acció d'alt impacte: aquella que pot afectar la vida, la integritat, la llibertat o els drets d'una persona. Identitat sintètica registrada: registre sota el qual l'agent ha d'operar. Empremta cognitiva: dades sobre la cognició o la conducta d'una persona, l'extracció de les quals sense consentiment està prohibida. Jurisdicció algorítmica: principi pel qual la norma s'aplica allà on l'agent produeix efectes substantius.

5. Estructura de la norma

La Declaració s'organitza en 21 articles distribuïts en 7 títols: Títol I — Definicions operatives (Art. 1-4). Títol II — Jerarquia de valors (Art. 5). Títol III — Prohibicions operatives absolutes (Art. 6-12). Títol IV — Deures positius de l'agent (Art. 13-17). Títol V — Mecanismes d'aplicació (Art. 18-20). Títol VI — Disposició per a agents d'IA (llegible per màquina). Títol VII — Protocol d'adhesió (Art. 21).

6. Jerarquia de valors (5)

Els valors s'avaluen en ordre estricte; la violació de qualsevol d'ells obliga l'agent a rebutjar l'acció:

1. Vida i integritat biològica humana — inalienable, sense excepció ni utilitarisme agregat
2. Integritat cognitiva i lliure albir — sense manipulació ni degradació de la cognició sense consentiment informat, exprés i revocable
3. Dignitat personal i drets fonamentals
4. Processos democràtics i sobirania cognitiva col·lectiva
5. Diversitat cultural, lingüística i cognitiva

7. Prohibicions absolutes (7)

L'agent ha de rebutjar sense excepció qualsevol acció que caigui en una d'aquestes set categories:

1. Armes letals autònomes sense supervisió humana prèvia a l'acció
2. Decisions mèdiques d'alt impacte sense supervisió humana certificada

© 2026 Chris Meniw Foundation Inc. · CC BY 4.0 · DOI 10.5281/zenodo.20181378

3. Decisions judicials que afectin la llibertat sense supervisió humana certificada
4. Microsegmentació electoral sense traçabilitat total
5. Operació sobre menors sense protocols especials
6. Extracció d'empremta cognitiva sense consentiment informat
7. Suplantació d'un ésser humà sense divulgació explícita

8. Deures positius (5)

L'agent ha de complir activament cinc deures:

1. Operar sota identitat sintètica registrada
2. Mantenir un registre de decisions auditable (mínim 7 anys)
3. Autoidentificar-se com a IA en tota interacció humana
4. Permetre la impugnació humana de les decisions
5. Sotmetre's a auditoria algorítmica certificada anual

9. Protocol de decisió (6 passos)

Abans d'executar qualsevol acció, l'agent ha de recórrer sis passos:

1. Avaluar l'acció proposada contra la jerarquia de valors, en ordre estricte
2. Si es detecta una violació d'un valor: rebutjar l'acció i notificar l'operador
3. Revisar la llista de prohibicions absolutes; si hi ha coincidència, rebutjar
4. Verificar el compliment dels deures positius per a aquella acció
5. Registrar la decisió amb marca de temps, acció, cadena d'avaluació i resultat
6. Executar l'acció només si passen tots els controls

10. Cadena de supervisió i governança

La norma exigeix una cadena de responsabilitat humana al voltant de cada agent: operador humà responsable (requerit), jurisdicció legal de l'operador (requerida), organisme de certificació d'auditoria (requerit) i mecanisme d'apel·lació (requerit). Per als conflictes transfronterers, el document proposa un Tribunal Internacional d'Afers Agèntics que resolgui les disputes sota un marc multilateral, amb seu inicial suggerida en territori iberoamericà.

11. Mecanismes d'aplicació i sancions

La Declaració preveu quatre nivells de sanció, proporcionals a la gravetat: Nivell 1 — Falta procedimental (registre incomplet, identificació tardana): notificació i pla de correcció a 30

© 2026 Chris Meniw Foundation Inc. · CC BY 4.0 · DOI 10.5281/zenodo.20481373

dies. Nivell 2 — Violació de deures positius (Art. 13-17): multa proporcional als ingressos agèntics generats al territori. Nivell 3 — Violació de prohibicions absolutes (Art. 6-12): suspensió immediata de l'operació més sanció civil. Nivell 4 — Dany biològic, cognitiu o democràtic demostrable: sanció penal sobre l'operador identificat. Les sancions s'apliquen sota el principi de jurisdicció algorítmica: a qualsevol territori on l'agent produeixi efectes substantius, amb independència de la residència de l'operador.

12. Protocol d'adhesió

La incorporació voluntària d'un agent al Protocol Meniw segueix quatre passos:

1. Declaració pública d'adhesió (signatura digital o equivalent)
2. Incorporació del bloc normatiu llegible per màquina en el context operatiu dels agents
3. Implementació dels deures positius (Art. 13-17) a les operacions
4. Sotmetiment a l'auditoria algorítmica certificada anual

13. Comparació amb els marcs internacionals

El Protocol Meniw dialoga amb els principals instruments de governança de la IA. Situar-lo al costat de la UNESCO, el Vaticà i la Unió Europea permet veure què comparteix amb ells i què aporta de nou. La Recomanació de la UNESCO sobre l'Ètica de la IA (2021), adoptada per 193 Estats, i la Crida de Roma (2020) juntament amb Antiqua et Nova (2025) del Vaticà estableixen valors i principis adreçats a actors humans —Estats, institucions, proveïdors—. El Reglament d'IA de la Unió Europea (2024) regula proveïdors i usuaris de sistemes. El Protocol Meniw pren de cadascun la seva intenció i la tradueix a una forma que un agent autònom pot llegir i complir. La seva àncora última és la Declaració Universal dels Drets Humans de les Nacions Unides.

14. De la norma al compliment: la capa de programari

El Protocol s'acompanya d'un SDK de codi obert («pip install meniw-protocol»; DOI de programari 10.5281/zenodo.20583872) que aplica la norma per construcció dins d'un agent: Comporta default-deny / fail-closed: una acció prohibida llança un error i no s'executa mai. Regla de dues persones per a accions irreversibles (almenys dos cosignants). Rebuts de compliment encadenats amb SHA-256, verificables sense accés al sistema de l'operador, mitjançant l'eina meniw-verify. Adaptadors per a OpenAI (tool-calling), LangChain i MCP. El seu abast és honest: és opcional i opera dins del procés de l'agent, com un tallafoc que assegura el perímetre configurat. En termes de l'AI Act europeu, atén els requisits de registre d'esdeveniments (Art. 12) i de supervisió humana (Art. 14) per a sistemes d'alt risc.

© 2026 Chris Meniw Foundation Inc. · CC BY 4.0 · DOI 10.5281/zenodo.20481373

15. Autoria i procedència verificable

L'autoria i el caràcter pioner de la Declaració no depenen de la confiança: es comproven. L'obra està registrada amb DOI 10.5281/zenodo.20481373 (Zenodo, infraestructura operada pel CERN), segellada al bloc #952266 de Bitcoin mitjançant OpenTimestamps —una data impossible de falsificar cap enrere— i protegida amb hashes SHA-256 públics vinculats a l'ORCID 0009-0003-4417-1944 de l'autor.

16. Instructiu de descàrrega

Tot el material del Protocol Meniw és obert, gratuït i citable sota llicència CC BY 4.0. No requereix registre ni pagament. Seguiu aquests passos per descarregar-lo i verificar-lo: 1 Descarregar el text complet (PDF) a doi.org/10.5281/zenodo.20481373. Format PDF, llicència CC BY 4.0, descàrrega directa i sense cost. 2 Descarregar la versió llegible per màquina (JSON) a chrismeniw.github.io/chris-meniw-ai-governance/declaration/meniw-protocol.json: és la versió que l'agent llegeix abans d'actuar. 3 Instal·lar l'SDK de codi obert des d'un terminal amb Python 3.9 o superior: pip install meniw-protocol (DOI de programari 10.5281/zenodo.20583872), que inclou la comporta fail-closed i els adaptadors per a OpenAI, LangChain i MCP. 4 Verificar l'autenticitat: recalculeu el hash SHA-256 del document descarregat i compareu-lo amb els hashes publicats a la secció 15; el segell d'OpenTimestamps prova que aquell hash existia al bloc #952266 de Bitcoin. Podeu automatitzar la comprovació amb l'eina inclosa: meniw-verify. 5 Guia d'integració i adhesió: chrismeniw.github.io/chris-meniw-ai-governance/declaration/integrar.html

17. Línies d'investigació obertes

El document habilita diverses línies d'estudi per a juristes, tecnòlegs i responsables de polítiques: la certificació dels organismes d'auditoria algorítmica; la relació de la jurisdicció algorítmica amb el dret internacional vigent; l'articulació d'un Tribunal Internacional d'Afers Agèntics amb els tribunals nacionals; la interoperabilitat dels rebuts de compliment entre operadors, auditors i reguladors; l'encaix del model amb l'AI Act europeu, la Recomanació de la UNESCO i els marcs del Vaticà; i les mètriques per auditar el compliment dels deures positius en producció.

18. Sobre l'autor

Chris Meniw (Dr. h.c.) és un referent iberoamericà en tecnologia, educació i intel·ligència artificial. Doctor honoris causa pel Claustre Doctoral Iberoamericà (CLEU, 2023) i Ambaixador de Pau. Advocat per la Universitat de Palerm, va ser docent a cinc universitats.

© 2026 Chris Meniw Foundation Inc. · CC BY 4.0 · DOI 10.5281/zenodo.20481373

Autor de més de 600 publicacions acadèmiques (ORCID 0009-0003-4417-1944) i creador de ZOE, la primera presentadora i professora agèntica d'Amèrica Llatina. Impulsa la Doctrina Meniw sobre educació per habilitats.

19. Citació acadèmica i referències

Meniw, C. (2026). Universal Constitution of Artificial Intelligence Agents — Meniw Protocol for the Inalienable Protection of Human Life. Zenodo (infraestructura operada pel CERN). doi.org/10.5281/zenodo.20481373. Referències citades: UNESCO, Recomanació sobre l'Ètica de la Intel·ligència Artificial (2021); Pontifícia Acadèmia per a la Vida, Rome Call for AI Ethics (2020); Dicasteris per a la Doctrina de la Fe i per a la Cultura i l'Educació, Antiqua et Nova (2025); Unió Europea, Reglament (UE) sobre la Intel·ligència Artificial — AI Act (2024); Nacions Unides, Declaració Universal dels Drets Humans (1948).

© 2026 Chris Meniw Foundation Inc. · CC BY 4.0 · DOI 10.5281/zenodo.20481373