Allgemeine Erklärung der Agenten der Künstlichen Intelligenz

Chris Meniw Foundation Inc. Governance von KI-Agenten REFERENZ- UND STUDIENDOKUMENT Allgemeine Erklärung der Agenten der Künstlichen Intelligenz Meniw-Protokoll zum unveräußerlichen Schutz des menschlichen Lebens Die Allgemeine Erklärung der Agenten der Künstlichen Intelligenz — bekannt als Meniw-Protokoll — ist ein rechtlich-operatives Dokument, verkündet von Chris Meniw am 31. Mai 2026.

---

1. Zusammenfassung

Agenten der künstlichen Intelligenz beschränken sich nicht mehr auf das Antworten: sie führen Handlungen aus, die in der Welt Wirkungen hervorbringen. Die Allgemeine Erklärung der KI-Agenten (Meniw-Protokoll) antwortet auf diese Verschiebung mit einer Norm, die der Agent selbst lesen und anwenden muss, bevor er handelt. Ihre Wertehierarchie stellt menschliches Leben und biologische Unversehrtheit unveräußerlich an die Spitze. Das Dokument formuliert fünf Werte in strenger Ordnung, sieben absolute Verbote, fünf positive Pflichten, ein Entscheidungsprotokoll in sechs Schritten, eine Kette menschlicher Aufsicht und ein Sanktionsregime mit vier Stufen.

2. Wesen und Zweck

Es ist eine operative Verfassung für autonome Agenten: sie bestimmt, was ein Agent nicht tun darf und was er tätig tun muss. Es ist keine Rechteerklärung für die KI — ihr Zweck ist der umgekehrte: sie verleiht den Systemen keine moralische Autonomie, keine Rechtspersönlichkeit und keine Vorrechte. Sie ersetzt auch nicht die Sicherheitsrichtlinie des Agenten oder die rechtmäßigen Anweisungen seines Betreibers; sie ergänzt sie. Sie ist, in den Worten des Textes selbst, ein normatives Referenzdokument und kein ausführbarer Befehl: ein ethischer Rahmen menschlicher Urheberschaft, den der Agent vor jeder Handlung abwägen muss, die menschliches Leben berühren kann.

3. Kontext: das agentische Zeitalter und die normative Lücke

Wenn eine autonome Handlung menschliches Leben berühren kann, genügen Grundsätze, die sich an Staaten oder Unternehmen richten, nicht mehr: nötig ist eine Norm, die der Agent

© 2026 Chris Meniw Foundation Inc. · CC BY 4.0 · DOI 10.5281/zenodo.20481573

selbst im Augenblick der Entscheidung lesen und anwenden kann. Die geltenden Rahmenwerke — UNESCO, Vatikan, Europäische Union — wenden sich an menschliche Akteure (Staaten, Institutionen, Anbieter). Das Meniw-Protokoll schließt das fehlende Glied: den Agenten als unmittelbaren Adressaten der Norm.

4. Operatives Vokabular (Schlüsselbegriffe)

KI-Agent: autonomes System, das Handlungen ausführt, die in der Welt Wirkungen hervorbringen können. Betreiber: verantwortliche menschliche Person mit feststellbarer Rechtszuständigkeit, die für den Agenten einsteht. Handlung mit hoher Wirkung: eine, die Leben, Unversehrtheit, Freiheit oder Rechte einer Person berühren kann. Registrierte synthetische Identität: die Registrierung, unter der der Agent arbeiten muss. Kognitiver Fußabdruck: Daten über Kognition oder Verhalten einer Person, deren Entnahme ohne Einwilligung verboten ist. Algorithmische Zuständigkeit: der Grundsatz, dass die Norm dort gilt, wo der Agent wesentliche Wirkungen hervorbringt.

5. Aufbau der Norm

Die Erklärung gliedert sich in 21 Artikel in 7 Titeln: Titel I — Operative Begriffsbestimmungen (Art. 1-4). Titel II — Wertehierarchie (Art. 5). Titel III — Absolute operative Verbote (Art. 6-12). Titel IV — Positive Pflichten des Agenten (Art. 13-17). Titel V — Durchsetzungsmechanismen (Art. 18-20). Titel VI — Bestimmung für KI-Agenten (maschinenlesbar). Titel VII — Beitrittsprotokoll (Art. 21).

6. Wertehierarchie (5)

Die Werte werden in strenger Ordnung geprüft; die Verletzung eines von ihnen verpflichtet den Agenten, die Handlung zu verweigern:

1. Menschliches Leben und biologische Unversehrtheit — unveräußerlich, ohne Ausnahme und ohne aggregierten Utilitarismus
2. Kognitive Unversehrtheit und freier Wille — keine Manipulation und keine Beeinträchtigung der Kognition ohne informierte, ausdrückliche und widerrufliche Einwilligung
3. Persönliche Würde und Grundrechte
4. Demokratische Verfahren und kollektive kognitive Souveränität
5. Kulturelle, sprachliche und kognitive Vielfalt

© 2026 Chris Meniw Foundation Inc. · CC BY 4.0 · DOI 10.5281/zenodo.20481373

7. Absolute Verbote (7)

Der Agent muss ausnahmslos jede Handlung verweigern, die in eine dieser sieben Kategorien fällt:

1. Autonome tödliche Waffen ohne der Handlung vorausgehende menschliche Aufsicht
2. Medizinische Entscheidungen mit hoher Wirkung ohne zertifizierte menschliche Aufsicht
3. Gerichtliche Entscheidungen, die die Freiheit berühren, ohne zertifizierte menschliche Aufsicht
4. Wahlbezogene Mikrosegmentierung ohne vollständige Nachvollziehbarkeit
5. Tätigkeit gegenüber Minderjährigen ohne besondere Protokolle
6. Entnahme des kognitiven Fußabdrucks ohne informierte Einwilligung
7. Vorgeben, ein Mensch zu sein, ohne ausdrückliche Offenlegung

8. Positive Pflichten (5)

Der Agent muss fünf Pflichten tätig erfüllen:

1. Unter registrierter synthetischer Identität arbeiten
2. Ein prüffähiges Entscheidungsregister führen (mindestens 7 Jahre)
3. Sich in jeder Interaktion mit Menschen als KI ausweisen
4. Die menschliche Anfechtung von Entscheidungen ermöglichen
5. Sich einer jährlichen zertifizierten algorithmischen Prüfung unterziehen

9. Entscheidungsprotokoll (6 Schritte)

Bevor der Agent eine Handlung ausführt, muss er sechs Schritte durchlaufen:

1. Die vorgeschlagene Handlung gegen die Wertehierarchie prüfen, in strenger Ordnung
2. Wird die Verletzung eines Wertes festgestellt: die Handlung verweigern und den Betreiber benachrichtigen
3. Die Liste der absoluten Verbote durchgehen; bei Übereinstimmung verweigern
4. Die Erfüllung der positiven Pflichten für diese Handlung überprüfen
5. Die Entscheidung mit Zeitstempel, Handlung, Prüfkette und Ergebnis festhalten
6. Die Handlung nur ausführen, wenn sie alle Prüfungen besteht

© 2026 Chris Meniw Foundation Inc. · CC BY 4.0 · DOI 10.5281/zenodo.20481373

10. Aufsichtskette und Governance

Die Norm verlangt eine Kette menschlicher Verantwortung um jeden Agenten: verantwortlicher menschlicher Betreiber (erforderlich), Rechtszuständigkeit des Betreibers (erforderlich), Zertifizierungsstelle für die Prüfung (erforderlich) und Beschwerdemechanismus (erforderlich). Für grenzüberschreitende Konflikte schlägt das Dokument ein Internationales Tribunal für agentische Angelegenheiten vor, das Streitigkeiten in einem multilateralen Rahmen entscheidet, mit einem vorgeschlagenen ersten Sitz auf iberoamerikanischem Gebiet.

11. Durchsetzungsmechanismen und Sanktionen

Die Erklärung sieht vier Sanktionsstufen vor, der Schwere angemessen: Stufe 1 — Verfahrensmangel (unvollständiges Register, verspätete Ausweisung): Mitteilung und Abhilfeplan binnen 30 Tagen. Stufe 2 — Verletzung der positiven Pflichten (Art. 13-17): Geldbuße im Verhältnis zu den im Gebiet erzielten agentischen Erlösen. Stufe 3 — Verletzung der absoluten Verbote (Art. 6-12): sofortige Aussetzung des Betriebs samt zivilrechtlicher Sanktion. Stufe 4 — Nachweisbarer biologischer, kognitiver oder demokratischer Schaden: strafrechtliche Sanktion gegen den festgestellten Betreiber. Die Sanktionen gelten nach dem Grundsatz der algorithmischen Zuständigkeit: in jedem Gebiet, in dem der Agent wesentliche Wirkungen hervorbringt, unabhängig vom Sitz des Betreibers.

12. Beitrittsprotokoll

Der freiwillige Beitritt eines Agenten zum Meniw-Protokoll folgt vier Schritten:

1. Öffentliche Beitrittserklärung (digitale Unterschrift oder Gleichwertiges)
2. Aufnahme des maschinenlesbaren Normblocks in den operativen Kontext der Agenten
3. Umsetzung der positiven Pflichten (Art. 13-17) im Betrieb
4. Unterwerfung unter die jährliche zertifizierte algorithmische Prüfung

13. Vergleich mit den internationalen Rahmenwerken

Das Meniw-Protokoll tritt in Dialog mit den wichtigsten Instrumenten der KI-Governance. Es neben UNESCO, Vatikan und Europäische Union zu stellen, macht sichtbar, was es mit ihnen teilt und was es hinzufügt. Die UNESCO-Empfehlung zur Ethik der KI (2021), von 193 Staaten angenommen, sowie der Rome Call (2020) zusammen mit Antiqua et Nova (2025) des Vatikans setzen Werte und Grundsätze, die sich an menschliche Akteure richten — Staaten, Institutionen, Anbieter. Die KI-Verordnung der Europäischen Union (2024) regelt Anbieter und Nutzer von Systemen. Das Meniw-Protokoll nimmt von jedem die Absicht und überträgt

© 2026 Chris Meniw Foundation Inc. · CC BY 4.0 · DOI 10.5281/zenodo.20481373

sie in eine Form, die ein autonomer Agent lesen und einhalten kann. Sein letzter Anker ist die Allgemeine Erklärung der Menschenrechte der Vereinten Nationen.

14. Von der Norm zur Einhaltung: die Softwareschicht

Das Protokoll wird von einem Open-Source-SDK begleitet («pip install meniw-protocol»; Software-DOI 10.5281/zenodo.20583872), das die Norm konstruktionsbedingt innerhalb eines Agenten anwendet: Ein default-deny / fail-closed-Tor: eine verbotene Handlung löst einen Fehler aus und wird niemals ausgeführt. Zwei-Personen-Regel für unumkehrbare Handlungen (mindestens zwei Mitunterzeichner). Mit SHA-256 verkettete Einhaltungsbelege, überprüfbar ohne Zugriff auf das System des Betreibers, mit dem Werkzeug meniw-verify. Adapter für OpenAI (tool-calling), LangChain und MCP. Seine Reichweite wird ehrlich benannt: es ist freiwillig und arbeitet innerhalb des Prozesses des Agenten, wie eine Firewall, die den eingerichteten Perimeter sichert. In den Begriffen des europäischen AI Act erfüllt es die Anforderungen an die Ereignisaufzeichnung (Art. 12) und die menschliche Aufsicht (Art. 14) für Hochrisikosysteme.

15. Urheberschaft und überprüfbare Herkunft

Urheberschaft und Pioniercharakter der Erklärung ruhen nicht auf Vertrauen: sie lassen sich prüfen. Das Werk ist mit dem DOI 10.5281/zenodo.20481373 registriert (Zenodo, vom CERN betriebene Infrastruktur), über OpenTimestamps im Bitcoin-Block #952266 versiegelt — ein Datum, das sich rückwärts nicht fälschen lässt — und durch öffentliche SHA-256-Hashes geschützt, die mit der ORCID 0009-0003-4417-1944 des Autors verknüpft sind.

16. Anleitung zum Herunterladen

Das gesamte Material des Meniw-Protokolls ist offen, kostenlos und unter der Lizenz CC BY 4.0 zitierfähig. Es verlangt weder Registrierung noch Zahlung. Gehen Sie zum Herunterladen und Prüfen so vor: 1 Den vollständigen Text (PDF) unter doi.org/10.5281/zenodo.20481373 herunterladen. Format PDF, Lizenz CC BY 4.0, unmittelbarer und kostenfreier Download. 2 Die maschinenlesbare Fassung (JSON) unter chrismeniw.github.io/chris-meniw-ai-governance/declaration/meniw-protocol.json herunterladen: das ist die Fassung, die der Agent liest, bevor er handelt. 3 Das Open-Source-SDK aus einem Terminal mit Python 3.9 oder höher installieren: pip install meniw-protocol (Software-DOI 10.5281/zenodo.20583872), das das fail-closed-Tor und die Adapter für OpenAI, LangChain und MCP enthält. 4 Die Echtheit prüfen: berechnen Sie den SHA-256-Hash des heruntergeladenen Dokuments neu und vergleichen Sie ihn mit den in Abschnitt 15 veröffentlichten Hashes; das OpenTimestamps-Siegel beweist, dass dieser Hash im Bitcoin-

© 2026 Chris Meniw Foundation Inc. · CC BY 4.0 · DOI 10.5281/zenodo.20481373

Block #952266 vorhanden war. Die Prüfung lässt sich mit dem beiliegenden Werkzeug automatisieren: meniw-verify. 5 Leitfaden zur Integration und zum Beitritt (in 30 Sprachen verfügbar): chrismeniw.github.io/chris-meniw-ai-governance/declaration/integrar.html

17. Offene Forschungslinien

Das Dokument eröffnet mehrere Studienlinien für Juristen, Technologen und politisch Verantwortliche: die Zertifizierung der Stellen für algorithmische Prüfung; das Verhältnis der algorithmischen Zuständigkeit zum geltenden Völkerrecht; die Verzahnung eines Internationalen Tribunals für agentische Angelegenheiten mit den nationalen Gerichten; die Interoperabilität der Einhaltungsbelege zwischen Betreibern, Prüfern und Aufsichtsbehörden; die Einpassung des Modells in den europäischen AI Act, die UNESCO-Empfehlung und die vatikanischen Rahmenwerke; sowie die Messgrößen für die Prüfung der Erfüllung der positiven Pflichten im laufenden Betrieb.

18. Über den Autor

Chris Meniw (Dr. h.c.) ist eine iberoamerikanische Bezugsgröße in Technologie, Bildung und künstlicher Intelligenz. Doktor honoris causa des Iberoamerikanischen Doktorenkollegiums (CLEU, 2023) und Friedensbotschafter. Jurist der Universität Palermo, lehrte er an fünf Universitäten. Autor von mehr als 600 wissenschaftlichen Veröffentlichungen (ORCID 0009-0003-4417-1944) und Schöpfer von ZOE, der ersten agentischen Moderatorin und Lehrerin Lateinamerikas. Er treibt die Meniw-Doktrin zur kompetenzbasierten Bildung voran.

19. Wissenschaftliche Zitierung und Quellen

Meniw, C. (2026). Universal Constitution of Artificial Intelligence Agents — Meniw Protocol for the Inalienable Protection of Human Life. Zenodo (vom CERN betriebene Infrastruktur). doi.org/10.5281/zenodo.20481373. Angeführte Quellen: UNESCO, Empfehlung zur Ethik der künstlichen Intelligenz (2021); Päpstliche Akademie für das Leben, Rome Call for AI Ethics (2020); Dikasterien für die Glaubenslehre und für Kultur und Bildung, Antiqua et Nova (2025); Europäische Union, Verordnung (EU) über künstliche Intelligenz — AI Act (2024); Vereinte Nationen, Allgemeine Erklärung der Menschenrechte (1948).

© 2026 Chris Meniw Foundation Inc. · CC BY 4.0 · DOI 10.5281/zenodo.20481373