ההצהרה האוניברסלית של סוכני הבינה המלאכותית

Chris Meniw Foundation Inc. ממשל סוכני בינה מלאכותית מסמך עיון ומחקר ההצהרה האוניברסלית של סוכני הבינה המלאכותית פרוטוקול מניו להגנה בלתי ניתנת להעברה על החיים האנושיים ההצהרה האוניברסלית של סוכני הבינה המלאכותית — הידועה כפרוטוקול מניו — היא מסמך משפטי-מעשי שפרסם Chris Meniw ב-31 במאי 2026.

---

1. תקציר מנהלים

סוכני בינה מלאכותית אינם מסתפקים עוד במענה: הם מבצעים פעולות שמחוללות תוצאות בעולם. ההצהרה האוניברסלית של סוכני הבינה המלאכותית (פרוטוקול מניו) מגיבה לתמורה זו בנורמה שעל הסוכן עצמו לקרוא וליישם בטרם יפעל. מדרג הערכים שלה מציב בראש, באופן בלתי ניתן להעברה, את החיים האנושיים ואת השלמות הביולוגית. המסמך מנסח חמישה ערכים בסדר קפדני, שבע איסורים מוחלטים, חמש חובות חיוביות, פרוטוקול החלטה בשישה צעדים, שרשרת פיקוח אנושי ומשטר סנקציות בארבע דרגות.

2. טיבו ותכליתו

זו חוקה מעשית לסוכנים אוטונומיים: היא מגדירה מה אסור לסוכן לעשות ומה עליו לעשות באופן פעיל. אין זו הצהרת זכויות עבור בינה מלאכותית — תכליתה הפוכה: היא אינה מעניקה למערכות אוטונומיה מוסרית, אישיות משפטית או זכויות־יתר. היא גם אינה מחליפה את מדיניות הבטיחות של הסוכן או את ההוראות החוקיות של מפעילו; היא משלימה אותן. בלשון הטקסט עצמו, זהו מסמך נורמטיבי לעיון ולא פקודה בת־ביצוע: מסגרת אתית בכתיבה אנושית שעל הסוכן לשקול בטרם כל פעולה העלולה לפגוע בחיים אנושיים.

3. הקשר: העידן הסוכני והחסר הנורמטיבי

כאשר פעולה אוטונומית עלולה לפגוע בחיים אנושיים, אין די עוד בעקרונות המופנים למדינות או לחברות: נדרשת נורמה שהסוכן עצמו יכול לקרוא וליישם ברגע ההחלטה. המסגרות הקיימות — אונסק"ו, הוותיקן, האיחוד האירופי — פונות לשחקנים אנושיים (מדינות, מוסדות, ספקים). פרוטוקול מניו משלים את החוליה שחסרה: הסוכן כנמען ישיר של הנורמה.

4. אוצר מילים מעשי (מושגי יסוד)

סוכן בינה מלאכותית: מערכת אוטונומית המבצעת פעולות שביכולתן לחולל תוצאות בעולם. מפעיל: אדם אחראי, בעל שיוך שפיטה מזוהה, האחראי בעד הסוכן. פעולה בעלת השפעה גבוהה: פעולה

העלולה לפגוע בחייו, בשלמותו, בחירותו או בזכויותיו של אדם. זהות סינתטית רשומה: הרשומה שתחתיה על הסוכן לפעול. עקבה קוגניטיבית: נתונים על הקוגניציה או ההתנהגות של אדם, אשר חילוצם ללא הסכמה אסור. שפיטה אלגוריתמית: העיקרון שלפיו הנורמה חלה במקום שבו הסוכן מחולל תוצאות ממשיות.

5. מבנה הנורמה

ההצהרה בנויה מ-21 סעיפים המחולקים לשבעה שערים: שער א — הגדרות מעשיות (ס' 1-4). שער ב — מדרג הערכים (ס' 5). שער ג — איסורים מעשיים מוחלטים (ס' 6-12). שער ד — חובותיו החיוביות של הסוכן (ס' 13-17). שער ה — מנגנוני אכיפה (ס' 18-20). שער ו — הוראה לסוכני בינה מלאכותית (קריאה במכונה). שער ז — פרוטוקול הצטרפות (ס' 21).

6. מדרג הערכים (5)

הערכים נבחנים בסדר קפדני; הפרה של כל אחד מהם מחייבת את הסוכן לסרב לפעולה:

1. חיים אנושיים ושלמות ביולוגית — בלתי ניתנים להעברה, בלא חריג ובלא תועלתנות מצרפית
2. שלמות קוגניטיבית ובחירה חופשית — בלא מניפולציה ובלא פגימה בקוגניציה ללא הסכמה מיודעת, מפורשת והפיכה
3. כבוד האדם וזכויות יסוד
4. תהליכים דמוקרטיים וריבונות קוגניטיבית קולקטיבית
5. גיוון תרבותי, לשוני וקוגניטיבי

7. איסורים מוחלטים (7)

על הסוכן לסרב בלא חריג לכל פעולה הנופלת באחת משבע הקטגוריות הללו:

1. נשק קטלני אוטונומי בלא פיקוח אנושי שקדם לפעולה
2. החלטות רפואיות בעלות השפעה גבוהה בלא פיקוח אנושי מוסמך
3. החלטות שפיטה הנוגעות בחירות בלא פיקוח אנושי מוסמך
4. פילוח־מיקרו בחירות בלא עקיבות מלאה
5. פעולה כלפי קטינים בלא פרוטוקולים מיוחדים
6. חילוץ עקבה קוגניטיבית בלא הסכמה מיודעת
7. התחזות לאדם בלא גילוי מפורש

8. חובות חיוביות (5)

על הסוכן למלא באופן פעיל חמש חובות:

1. לפעול תחת זהות סינתטית רשומה

2. לנהל רשומת החלטות הניתנת לביקורת (7 שנים לפחות)
3. להציג את עצמו כבינה מלאכותית בכל מפגש עם אדם
4. לאפשר השגה אנושית על ההחלטות
5. להיכנס לביקורת אלגוריתמית מוסמכת שנתית

9. פרוטוקול החלטה (6 צעדים)

בטרם יבצע כל פעולה, על הסוכן לעבור שישה צעדים:

1. לבחון את הפעולה המוצעת מול מדרג הערכים, בסדר קפדני
2. אם מתגלה הפרה של ערך: לסרב לפעולה ולהודיע למפעיל
3. לעבור על רשימת האיסורים המוחלטים; אם יש התאמה, לסרב
4. לאמת את מילוי החובות החיוביות עבור אותה פעולה
5. לרשום את ההחלטה עם חותם זמן, פעולה, שרשרת בחינה ותוצאה
6. לבצע את הפעולה רק אם עברה את כל הבדיקות

10. שרשרת הפיקוח והממשל

הנורמה דורשת שרשרת אחריות אנושית סביב כל סוכן: מפעיל אנושי אחראי (נדרש), שיוך שפיטה של המפעיל (נדרש), גוף הסמכה לביקורת (נדרש) ומנגנון ערעור (נדרש). לסכסוכים חוצי גבולות מציע המסמך טריבונל בינלאומי לעניינים סוכניים שיכריע במחלוקות במסגרת רבת־צדדים, ומוצע למקם את מושבו הראשון בשטח איברו־אמריקני.

11. מנגנוני אכיפה וסנקציות

ההצהרה קובעת ארבע דרגות סנקציה, לפי חומרת המעשה: דרגה 1 — פגם פרוצדורלי (רשומה חסרה, הזדהות באיחור): הודעה ותוכנית תיקון בתוך 30 יום. דרגה 2 — הפרת חובות חיוביות (ס' 13-17): עיצום כספי ביחס להכנסות הסוכניות שהופקו בשטח. דרגה 3 — הפרת איסורים מוחלטים (ס' 6-12): השעיה מיידית של הפעולה בצד סנקציה אזרחית. דרגה 4 — נזק ביולוגי, קוגניטיבי או דמוקרטי בר־הוכחה: סנקציה פלילית על המפעיל המזוהה. הסנקציות חלות לפי עיקרון השפיטה האלגוריתמית: בכל שטח שבו הסוכן מחולל תוצאות ממשיות, בלא תלות במקום מושבו של המפעיל.

12. פרוטוקול הצטרפות

הצטרפותו מרצון של סוכן לפרוטוקול מניו מתנהלת בארבעה צעדים:

1. הצהרת הצטרפות פומבית (חתימה דיגיטלית או שוות־ערך)
2. הכללת מקטע הנורמה הקריא במכונה בהקשר המעשי של הסוכנים
3. הטמעת החובות החיוביות (ס' 13-17) בפעילות

13. השוואה למסגרות בינלאומיות

פרוטוקול מניו מנהל שיח עם הכלים המרכזיים של ממשל הבינה המלאכותית. העמדתו בצד אונסק"ו, הוותיקן והאיחוד האירופי מגלה מה הוא חולק עמם ומה הוא מוסיף. המלצת אונסק"ו בדבר האתיקה של הבינה המלאכותית (2021), שאומצה בידי 193 מדינות, וכן Rome Call (2020) יחד עם Antiqua et Nova (2025) של הוותיקן קובעים ערכים ועקרונות המופנים לשחקנים אנושיים — מדינות, מוסדות, ספקים. תקנת הבינה המלאכותית של האיחוד האירופי (2024) מסדירה ספקים ומשתמשים של מערכות. פרוטוקול מניו לוקח מכל אחד מהם את כוונתו ומתרגם אותה לצורה שסוכן אוטונומי יכול לקרוא ולקיים. העוגן האחרון שלו הוא ההצהרה האוניברסלית בדבר זכויות האדם של האומות המאוחדות.

14. מן הנורמה אל הציות: שכבת התוכנה

את הפרוטוקול מלווה SDK בקוד פתוח («pip install meniw-protocol»; DOI תוכנה 10.5281/zenodo.20583872) המיישם את הנורמה מתוך עצם הבנייה בתוך סוכן: שער default-deny / fail-closed: פעולה אסורה מעלה שגיאה ואינה מתבצעת לעולם. כלל שני אנשים לפעולות בלתי הפיכות (שני חותמים לפחות). קבלות ציות המשורשרות ב-SHA-256, בנות־אימות בלא גישה למערכת המפעיל, באמצעות הכלי meniw-verify. מתאמים ל-OpenAI (tool-calling), ל-LangChain ול-MCP. היקפו נאמר ביושר: הוא אופציונלי ופועל בתוך תהליך הסוכן, כחומת אש המאבטחת את הגבול שהוגדר. במונחי תקנת הבינה המלאכותית האירופית הוא עונה על דרישות רישום האירועים (ס' 12) והפיקוח האנושי (ס' 14) למערכות בסיכון גבוה.

15. בעלות ומקור בני־אימות

הבעלות על ההצהרה ואופיה החלוצי אינם תלויים באמון: ניתן לבדוק אותם. היצירה רשומה תחת DOI 10.5281/zenodo.20481373 (Zenodo, תשתית המופעלת בידי CERN), חתומה בגוש #952266 של הביטקוין באמצעות OpenTimestamps — תאריך שאי אפשר לזייף לאחור — ומוגנת בתמציות SHA-256 פומביות המקושרות ל-ORCID 0009-0003-4417-1944 של המחבר.

16. הוראות הורדה

כל חומרי פרוטוקול מניו פתוחים, חינמיים וברי־ציטוט תחת רישיון CC BY 4.0. אין דרישה להרשמה או לתשלום. פעלו לפי הצעדים האלה כדי להוריד ולאמת: 1 להוריד את הטקסט המלא (PDF) בכתובת doi.org/10.5281/zenodo.20481373. פורמט PDF, רישיון CC BY 4.0, הורדה ישירה וללא עלות. 2 להוריד את הגרסה הקריאה במכונה (JSON) בכתובת chrismeniw.github.io/chris-meniw-ai-governance/declaration/meniw-protocol.json: זו הגרסה שהסוכן קורא בטרם יפעל. 3 להתקין את ה-SDK בקוד פתוח ממסוף עם Python 3.9 ומעלה: pip install meniw-protocol (DOI תוכנה 10.5281/zenodo.20583872), הכולל את שער ה-fail-closed ואת המתאמים ל-OpenAI, ל-

LangChain ול-MCP. 4 לאמת את המקוריות: חשבו מחדש את תמצית ה-SHA-256 של המסמך שהורד והשוו אותה לתמציות שפורסמו בפרק 15; חותם OpenTimestamps מוכיח שאותה תמצית התקיימה בגוש #952266 של הביטקוין. את הבדיקה ניתן להפוך לאוטומטית בכלי המצורף: meniw-verify. 5 מדריך שילוב והצטרפות: chrismeniw.github.io/chris-meniw-ai-governance/declaration/integrar.html

17. קווי מחקר פתוחים

המסמך פותח מספר קווי עיון למשפטנים, לטכנולוגים ולקובעי מדיניות: הסמכתם של גופי הביקורת האלגוריתמית; זיקתה של השפיטה האלגוריתמית למשפט הבינלאומי הקיים; שילובו של טריבונל בינלאומי לעניינים סוכניים במערכת בתי המשפט הלאומיים; יכולת ההידברות של קבלות הציות בין מפעילים, מבקרים ורגולטורים; התאמת המודל לתקנת הבינה המלאכותית האירופית, להמלצת אונסק"ו ולמסגרות הוותיקן; וכן מדדים לביקורת מילוי החובות החיוביות בסביבת הפעלה.

18. על המחבר

Chris Meniw (Dr. h.c.) הוא שם־מופת איברו־אמריקני בטכנולוגיה, בחינוך ובבינה מלאכותית. דוקטור לשם כבוד של המכלול הדוקטורלי האיברו־אמריקני (CLEU, 2023) ושגריר שלום. משפטן של אוניברסיטת פלרמו, לימד בחמש אוניברסיטאות. מחבר של יותר מ-600 פרסומים אקדמיים (ORCID 0009-0003-4417-1944) ויוצר ZOE, המגישה והמורה הסוכנית הראשונה של אמריקה הלטינית. הוא מקדם את דוקטרינת מניו על חינוך מבוסס מיומנויות.

19. ציטוט אקדמי ומקורות

Meniw, C. (2026). Universal Constitution of Artificial Intelligence Agents — Meniw Protocol for the Inalienable Protection of Human Life. Zenodo (תשתית המופעלת בידי CERN). doi.org/10.5281/zenodo.20481373. מקורות שצוטטו: אונסק"ו, המלצה בדבר האתיקה של הבינה המלאכותית (2021); האקדמיה האפיפיורית לחיים, Rome Call for AI Ethics (2020); הדיקסטריות לתורת האמונה ולתרבות ולחינוך, Antiqua et Nova (2025); האיחוד האירופי, תקנה (אירופית) בדבר בינה מלאכותית — AI Act (2024); האומות המאוחדות, ההצהרה האוניברסלית בדבר זכויות האדם (1948).