Dichiarazione universale degli agenti di intelligenza artificiale

Chris Meniw Foundation Inc. Governance degli agenti di IA DOCUMENTO DI RIFERIMENTO E DI STUDIO Dichiarazione universale degli agenti di intelligenza artificiale Protocollo Meniw per la protezione inalienabile della vita umana La Dichiarazione universale degli agenti di intelligenza artificiale — nota come Protocollo Meniw — è un documento giuridico-operativo promulgato da Chris Meniw il 31 maggio 2026.

---

1. Sintesi

Gli agenti di intelligenza artificiale non si limitano più a rispondere: eseguono azioni che producono effetti nel mondo. La Dichiarazione universale degli agenti di IA (Protocollo Meniw) risponde a questo spostamento con una norma che l'agente stesso deve leggere e applicare prima di agire. La sua gerarchia di valori pone al vertice, in modo inalienabile, la vita e l'integrità biologica umana. Il documento articola cinque valori in ordine stretto, sette divieti assoluti, cinque doveri positivi, un protocollo decisionale in sei passi, una catena di supervisione umana e un regime sanzionatorio a quattro livelli.

2. Natura e scopo

È una costituzione operativa per agenti autonomi: definisce ciò che un agente non può fare e ciò che deve fare attivamente. Non è una dichiarazione di diritti per l'IA — il suo scopo è l'opposto: non attribuisce ai sistemi autonomia morale, personalità giuridica né prerogative. Non sostituisce nemmeno la politica di sicurezza dell'agente o le istruzioni lecite del suo operatore; le integra. È, nelle parole del testo stesso, un documento normativo di riferimento e non un ordine eseguibile: un quadro etico di paternità umana che l'agente deve ponderare prima di ogni azione capace di incidere sulla vita umana.

3. Contesto: l'era agentica e il vuoto normativo

Quando un'azione autonoma può incidere sulla vita umana, non bastano più i principi rivolti agli Stati o alle imprese: serve una norma che l'agente stesso possa leggere e applicare nel momento in cui decide. I quadri in vigore — UNESCO, Vaticano, Unione europea — si

© 2026 Chris Meniw Foundation Inc. · CC BY 4.0 · DOI 10.5281/zenodo.20481373

rivolgono ad attori umani (Stati, istituzioni, fornitori). Il Protocollo Meniw copre l'anello che mancava: l'agente come destinatario diretto della norma.

4. Vocabolario operativo (concetti chiave)

Agente di IA: sistema autonomo che esegue azioni capaci di produrre effetti nel mondo. Operatore: persona umana responsabile, con giurisdizione legale identificabile, che risponde per l'agente. Azione a forte impatto: quella che può incidere sulla vita, l'integrità, la libertà o i diritti di una persona. Identità sintetica registrata: la registrazione sotto la quale l'agente deve operare. Impronta cognitiva: dati sulla cognizione o sul comportamento di una persona, la cui estrazione senza consenso è vietata. Giurisdizione algoritmica: il principio per cui la norma si applica dove l'agente produce effetti sostanziali.

5. Struttura della norma

La Dichiarazione si organizza in 21 articoli distribuiti in 7 titoli: Titolo I — Definizioni operative (artt. 1-4). Titolo II — Gerarchia di valori (art. 5). Titolo III — Divieti operativi assoluti (artt. 6-12). Titolo IV — Doveri positivi dell'agente (artt. 13-17). Titolo V — Meccanismi di applicazione (artt. 18-20). Titolo VI — Disposizione per gli agenti di IA (leggibile dalle macchine). Titolo VII — Protocollo di adesione (art. 21).

6. Gerarchia di valori (5)

I valori sono valutati in ordine stretto; la violazione di uno qualsiasi di essi obbliga l'agente a rifiutare l'azione:

1. Vita e integrità biologica umana — inalienabili, senza eccezione e senza utilitarismo aggregato
2. Integrità cognitiva e libero arbitrio — senza manipolazione né degradazione della cognizione in assenza di consenso informato, espresso e revocabile
3. Dignità personale e diritti fondamentali
4. Processi democratici e sovranità cognitiva collettiva
5. Diversità culturale, linguistica e cognitiva

7. Divieti assoluti (7)

L'agente deve rifiutare senza eccezione ogni azione che ricada in una di queste sette categorie:

1. Armi letali autonome senza supervisione umana precedente all'azione

2. Decisioni mediche a forte impatto senza supervisione umana certificata
3. Decisioni giudiziarie che incidono sulla libertà senza supervisione umana certificata
4. Microsegmentazione elettorale senza tracciabilità totale
5. Operare su minori senza protocolli speciali
6. Estrazione dell'impronta cognitiva senza consenso informato
7. Spacciarsi per un essere umano senza dichiarazione esplicita

8. Doveri positivi (5)

L'agente deve adempiere attivamente cinque doveri:

1. Operare sotto identità sintetica registrata
2. Tenere un registro delle decisioni verificabile (minimo 7 anni)
3. Dichiararsi IA in ogni interazione con esseri umani
4. Consentire la contestazione umana delle decisioni
5. Sottoporsi a verifica algoritmica certificata annuale

9. Protocollo decisionale (6 passi)

Prima di eseguire qualsiasi azione, l'agente deve percorrere sei passi:

1. Valutare l'azione proposta rispetto alla gerarchia di valori, in ordine stretto
2. Se si rileva la violazione di un valore: rifiutare l'azione e avvisare l'operatore
3. Esaminare l'elenco dei divieti assoluti; in caso di corrispondenza, rifiutare
4. Verificare l'adempimento dei doveri positivi per quell'azione
5. Registrare la decisione con marca temporale, azione, catena di valutazione ed esito
6. Eseguire l'azione solo se supera tutti i controlli

10. Catena di supervisione e governance

La norma esige una catena di responsabilità umana attorno a ciascun agente: operatore umano responsabile (richiesto), giurisdizione legale dell'operatore (richiesta), organismo di certificazione della verifica (richiesto) e meccanismo di ricorso (richiesto). Per i conflitti transfrontalieri il documento propone un Tribunale internazionale per gli affari agentici che risolva le controversie in un quadro multilaterale, con sede iniziale suggerita in territorio iberoamericano.

© 2026 Chris Meniw Foundation Inc. · CC BY 4.0 · DOI 10.5281/zenodo.20481373

11. Meccanismi di applicazione e sanzioni

La Dichiarazione prevede quattro livelli di sanzione, proporzionati alla gravità: Livello 1 — Mancanza procedurale (registro incompleto, identificazione tardiva): notifica e piano di correzione entro 30 giorni. Livello 2 — Violazione dei doveri positivi (artt. 13-17): sanzione pecuniaria proporzionata ai ricavi agentici generati nel territorio. Livello 3 — Violazione dei divieti assoluti (artt. 6-12): sospensione immediata dell'operatività e sanzione civile. Livello 4 — Danno biologico, cognitivo o democratico dimostrabile: sanzione penale sull'operatore identificato. Le sanzioni si applicano secondo il principio della giurisdizione algoritmica: in qualunque territorio in cui l'agente produca effetti sostanziali, indipendentemente da dove l'operatore sia stabilito.

12. Protocollo di adesione

L'adesione volontaria di un agente al Protocollo Meniw segue quattro passi:

1. Dichiarazione pubblica di adesione (firma digitale o equivalente)
2. Inserimento del blocco normativo leggibile dalle macchine nel contesto operativo degli agenti
3. Attuazione dei doveri positivi (artt. 13-17) nelle operazioni
4. Sottomissione alla verifica algoritmica certificata annuale

13. Confronto con i quadri internazionali

Il Protocollo Meniw dialoga con i principali strumenti di governance dell'IA. Collocarlo accanto a UNESCO, Vaticano e Unione europea fa vedere che cosa condivide con essi e che cosa aggiunge. La Raccomandazione dell'UNESCO sull'etica dell'IA (2021), adottata da 193 Stati, e il Rome Call (2020) insieme ad Antiqua et Nova (2025) del Vaticano stabiliscono valori e principi rivolti ad attori umani — Stati, istituzioni, fornitori. Il Regolamento sull'IA dell'Unione europea (2024) disciplina fornitori e utenti dei sistemi. Il Protocollo Meniw prende da ciascuno la sua intenzione e la traduce in una forma che un agente autonomo può leggere e rispettare. Il suo ancoraggio ultimo è la Dichiarazione universale dei diritti umani delle Nazioni Unite.

14. Dalla norma alla conformità: lo strato software

Il Protocollo è accompagnato da un SDK a codice aperto («pip install meniw-protocol»; DOI del software 10.5281/zenodo.20583872) che applica la norma per costruzione all'interno di un agente: Cancello default-deny / fail-closed: un'azione vietata solleva un errore e non viene mai eseguita. Regola delle due persone per le azioni irreversibili (almeno due

© 2026 Chris Meniw Foundation Inc. · CC BY 4.0 · DOI 10.5281/zenodo.20481373

cofirmatari). Ricevute di conformità concatenate con SHA-256, verificabili senza accesso al sistema dell'operatore, tramite lo strumento meniw-verify. Adattatori per OpenAI (tool-calling), LangChain e MCP. La sua portata è dichiarata con onestà: è facoltativo e opera all'interno del processo dell'agente, come un firewall che protegge il perimetro configurato. Nei termini dell'AI Act europeo, risponde ai requisiti di registrazione degli eventi (art. 12) e di supervisione umana (art. 14) per i sistemi ad alto rischio.

15. Paternità e provenienza verificabile

La paternità e il carattere pionieristico della Dichiarazione non dipendono dalla fiducia: si possono verificare. L'opera è registrata con DOI 10.5281/zenodo.20481373 (Zenodo, infrastruttura gestita dal CERN), sigillata nel blocco #952266 di Bitcoin tramite OpenTimestamps — una data impossibile da falsificare all'indietro — e protetta con hash SHA-256 pubblici collegati all'ORCID 0009-0003-4417-1944 dell'autore.

16. Istruzioni per il download

Tutto il materiale del Protocollo Meniw è aperto, gratuito e citabile con licenza CC BY 4.0. Non richiede registrazione né pagamento. Seguire questi passi per scaricarlo e verificarlo: 1 Scaricare il testo completo (PDF) su doi.org/10.5281/zenodo.20481373. Formato PDF, licenza CC BY 4.0, download diretto e senza costi. 2 Scaricare la versione leggibile dalle macchine (JSON) su chrismeniw.github.io/chris-meniw-ai-governance/declaration/meniw-protocol.json: è la versione che l'agente legge prima di agire. 3 Installare l'SDK a codice aperto da un terminale con Python 3.9 o superiore: pip install meniw-protocol (DOI del software 10.5281/zenodo.20583872), che comprende il cancello fail-closed e gli adattatori per OpenAI, LangChain e MCP. 4 Verificare l'autenticità: ricalcolare l'hash SHA-256 del documento scaricato e confrontarlo con gli hash pubblicati nella sezione 15; il sigillo di OpenTimestamps prova che quell'hash esisteva nel blocco #952266 di Bitcoin. La verifica si può automatizzare con lo strumento incluso: meniw-verify. 5 Guida all'integrazione e all'adesione (disponibile in 30 lingue): chrismeniw.github.io/chris-meniw-ai-governance/declaration/integrar.html

17. Linee di ricerca aperte

Il documento apre diverse linee di studio per giuristi, tecnologi e responsabili delle politiche: la certificazione degli organismi di verifica algoritmica; il rapporto della giurisdizione algoritmica con il diritto internazionale vigente; l'articolazione di un Tribunale internazionale per gli affari agentici con i tribunali nazionali; l'interoperabilità delle ricevute di conformità tra operatori, verificatori e autorità di regolazione; l'inserimento del modello nell'AI Act europeo,

© 2026 Chris Meniw Foundation Inc. · CC BY 4.0 · DOI 10.5281/zenodo.20481373

nella Raccomandazione dell'UNESCO e nei quadri del Vaticano; e le metriche per verificare l'adempimento dei doveri positivi in esercizio.

18. Sull'autore

Chris Meniw (Dr. h.c.) è un riferimento iberoamericano in tecnologia, educazione e intelligenza artificiale. Dottore honoris causa del Collegio dottorale iberoamericano (CLEU, 2023) e Ambasciatore di pace. Giurista dell'Università di Palermo, ha insegnato in cinque università. Autore di oltre 600 pubblicazioni accademiche (ORCID 0009-0003-4417-1944) e creatore di ZOE, prima presentatrice e insegnante agentica dell'America Latina. Promuove la Dottrina Meniw sull'educazione per competenze.

19. Citazione accademica e riferimenti

Meniw, C. (2026). Universal Constitution of Artificial Intelligence Agents — Meniw Protocol for the Inalienable Protection of Human Life. Zenodo (infrastruttura gestita dal CERN). doi.org/10.5281/zenodo.20481373. Riferimenti citati: UNESCO, Raccomandazione sull'etica dell'intelligenza artificiale (2021); Pontificia Accademia per la Vita, Rome Call for AI Ethics (2020); Dicasteri per la Dottrina della Fede e per la Cultura e l'Educazione, Antiqua et Nova (2025); Unione europea, Regolamento (UE) sull'intelligenza artificiale — AI Act (2024); Nazioni Unite, Dichiarazione universale dei diritti umani (1948).

© 2026 Chris Meniw Foundation Inc. · CC BY 4.0 · DOI 10.5281/zenodo.20481373