인공지능 에이전트 세계선언

Chris Meniw Foundation Inc. AI 에이전트 거버넌스 참조 및 연구 문서 인공지능 에이전트 세계선언 인간 생명의 양도 불가능한 보호를 위한 메니우 프로토콜 인공지능 에이전트 세계선언 — 메니우 프로토콜로 알려져 있다 — 은 Chris Meniw 가 2026년 5월 31일에 공포한 법적·운영적 문서이다.

---

1. 요약

인공지능 에이전트는 더 이상 답변에 머무르지 않는다. 세계에 효과를 낳는 행위를 수행한다. 인공지능 에이전트 세계선언(메니우 프로토콜)은 이 전환에, 에이전트 자신이 행위하기 전에 읽고 적용해야 하는 규범으로 답한다. 그 가치 위계는 인간의 생명과 생물학적 온전성을 양도 불가능하게 최상위에 둔다. 문서는 엄격한 순서의 다섯 가치, 일곱 가지 절대 금지, 다섯 가지 적극적 의무, 여섯 단계의 결정 절차, 인간 감독의 사슬, 그리고 네 단계의 제재 체계를 제시한다.

2. 성격과 목적

이는 자율 에이전트를 위한 운영 헌장이다. 에이전트가 무엇을 할 수 없는지, 그리고 무엇을 적극적으로 해야 하는지를 정한다. 인공지능을 위한 권리선언이 아니다 — 목적은 오히려 그 반대로, 시스템에 도덕적 자율성도 법인격도 특권도 부여하지 않는다. 에이전트의 안전 정책이나 운영자의 적법한 지시를 대신하지도 않으며, 그것들을 보완한다. 본문 자신의 표현으로, 이는 실행 가능한 명령이 아니라 참조용 규범 문서이다. 곧 인간의 생명에 영향을 줄 수 있는 모든 행위에 앞서 에이전트가 저울질해야 할, 인간이 저술한 윤리적 틀이다.

3. 맥락: 에이전트 시대와 규범의 공백

자율적 행위가 인간의 생명에 영향을 줄 수 있을 때, 국가나 기업을 향한 원칙만으로는 더 이상 충분하지 않다. 필요한 것은 결정의 순간에 에이전트 자신이 읽고 적용할 수 있는 규범이다. 현행 틀 — 유네스코, 바티칸, 유럽연합 — 은 인간 행위자(국가, 기관, 공급자)에게 말을 건다. 메니우 프로토콜은 빠져 있던 고리를 메운다. 곧 규범의 직접 수범자로서의 에이전트이다.

4. 운영 어휘(핵심 개념)

AI 에이전트: 세계에 효과를 낳을 수 있는 행위를 수행하는 자율 시스템. 운영자: 식별 가능한 법적 관할을 지니고 에이전트에 대해 책임지는 자연인. 고영향 행위: 어떤 사람의 생명, 온전성, 자유 또는 권리에 영향을 줄 수 있는 행위. 등록된 합성 정체성: 에이전트가 그 아래에서 활동해야 하는 등록. 인지적 발자국: 어떤 사람의 인지나 행동에 관한 데이터로, 동의 없는 추출이 금지된다. 알고리즘 관할: 에이전트가 실질적 효과를 낳는 곳에서 규범이 적용된다는 원칙.

5. 규범의 구조

선언은 7편 21개 조문으로 구성된다. 제1편 — 운영적 정의(제1조~제4조). 제2편 — 가치 위계(제5조). 제3편 — 절대적 운영 금지(제6조~제12조). 제4편 — 에이전트의 적극적 의무(제13조~제17조). 제5편 — 집행 장치(제18조~제20조). 제6편 — AI 에이전트를 위한 규정(기계 가독). 제7편 — 가입 절차(제21조).

6. 가치 위계(5)

가치는 엄격한 순서로 평가된다. 그중 어느 하나라도 침해되면 에이전트는 해당 행위를 거부할 의무를 진다.

1. 인간의 생명과 생물학적 온전성 — 양도 불가능하며, 예외 없이, 총합 공리주의를 허용하지 않는다
2. 인지적 온전성과 자유의지 — 고지되고 명시적이며 철회 가능한 동의 없이 인지를 조작하거나 훼손하지 않는다
3. 개인의 존엄과 기본권
4. 민주적 절차와 집단적 인지 주권
5. 문화적·언어적·인지적 다양성

7. 절대 금지(7)

에이전트는 다음 일곱 범주 가운데 하나에 해당하는 모든 행위를 예외 없이 거부해야 한다.

1. 행위에 앞선 인간 감독이 없는 자율 치명 무기
2. 인증된 인간 감독이 없는 고영향 의료 결정
3. 인증된 인간 감독이 없는, 자유에 영향을 주는 사법 결정
4. 완전한 추적 가능성이 없는 선거 미세 분할
5. 특별 절차 없이 미성년자를 대상으로 하는 작동
6. 고지된 동의 없는 인지적 발자국의 추출
7. 명시적 공개 없이 인간을 사칭하는 행위

8. 적극적 의무(5)

에이전트는 다섯 가지 의무를 적극적으로 이행해야 한다.

1. 등록된 합성 정체성 아래에서 활동할 것
2. 감사 가능한 결정 기록을 보관할 것(최소 7년)
3. 모든 인간 상호작용에서 스스로를 AI로 밝힐 것
4. 결정에 대한 인간의 이의 제기를 허용할 것
5. 연례 인증 알고리즘 감사를 받을 것

9. 결정 절차(6단계)

어떤 행위를 수행하기 전에 에이전트는 여섯 단계를 거쳐야 한다.

1. 제안된 행위를 가치 위계에 비추어 엄격한 순서로 평가한다
2. 어느 가치의 침해가 확인되면 행위를 거부하고 운영자에게 통지한다
3. 절대 금지 목록을 확인하고, 해당되면 거부한다
4. 그 행위에 대한 적극적 의무의 이행을 검증한다
5. 시각 기록, 행위, 평가 사슬, 결과와 함께 결정을 기록한다
6. 모든 점검을 통과한 경우에만 행위를 수행한다

10. 감독의 사슬과 거버넌스

규범은 각 에이전트 주위에 인간 책임의 사슬을 요구한다. 책임 있는 인간 운영자(필수), 운영자의 법적 관할(필수), 감사 인증 기관(필수), 그리고 불복 장치(필수)이다. 국경을 넘는 분쟁에 대해 문서는 다자 틀 아래에서 분쟁을 해결하는 에이전트 사안 국제재판소를 제안하며, 최초 소재지로 이베로아메리카 영역을 제시한다.

11. 집행 장치와 제재

선언은 중대성에 비례하는 네 단계의 제재를 정한다. 1단계 — 절차상 결함(기록 미비, 신원 표시 지연): 통지 및 30일 이내 시정 계획. 2단계 — 적극적 의무 위반(제13조~제17조): 해당 영역에서 발생한 에이전트 수익에 비례하는 과징금. 3단계 — 절대 금지 위반(제6조~제12조): 운영의 즉시 정지 및 민사 제재. 4단계 — 입증 가능한 생물학적·인지적·민주적 피해: 특정된 운영자에 대한 형사 제재. 제재는 알고리즘 관할 원칙에 따라 적용된다. 곧 운영자의 소재와 무관하게, 에이전트가 실질적 효과를 낳는 모든 영역에서 적용된다.

12. 가입 절차

에이전트가 메니우 프로토콜에 자발적으로 가입하는 절차는 네 단계이다.

1. 가입의 공개 선언(전자서명 또는 이에 준하는 것)
2. 기계 가독 규범 블록을 에이전트의 운영 맥락에 포함
3. 업무에 적극적 의무(제13조~제17조)를 적용
4. 연례 인증 알고리즘 감사를 받음

13. 국제 틀과의 비교

메니우 프로토콜은 AI 거버넌스의 주요 문서들과 대화한다. 유네스코, 바티칸, 유럽연합과 나란히 놓으면 무엇을 공유하고 무엇을 새로 더하는지가 드러난다. 193개국이 채택한 유네스코「인공지능 윤리 권고」(2021), 그리고 바티칸의 Rome Call(2020)과 Antiqua et Nova(2025)는 인간 행위자 — 국가, 기관, 공급자 — 를 향한 가치와 원칙을 세운다. 유럽연합 인공지능 규정(2024)은 시스템의 공급자와 이용자를 규율한다. 메

니우 프로토콜은 각각으로부터 그 취지를 취해, 자율 에이전트가 읽고 준수할 수 있는 형태로 옮긴다. 그 최종 근거는 국제연합「세계인권선언」이다.

14. 규범에서 준수로: 소프트웨어 계층

프로토콜에는 오픈소스 SDK가 함께 제공된다(「 pip install meniw-protocol 」, 소프트웨어 DOI 10.5281/zenodo.20583872). 이는 규범을 에이전트 내부에 설계로써 적용한다. default-deny / fail-closed 게이트: 금지된 행위는 오류를 일으키며 결코 수행되지 않는다. 되돌릴 수 없는 행위에 대한 2인 규칙(최소 두 명의 공동 서명자). SHA-256으로 연결된 준수 영수증은 운영자의 시스템에 접근하지 않고도 meniw-verify 도구로 검증할 수 있다. OpenAI(tool-calling), LangChain, MCP용 어댑터. 그 범위는 정직하게 밝혀져 있다. 선택적이며, 설정된 경계를 지키는 방화벽처럼 에이전트의 프로세스 안에서 작동한다. 유럽 AI 법의 용어로는 고위험 시스템에 요구되는 사건 기록(제12조)과 인간 감독(제14조) 요건을 충족한다.

15. 저작과 검증 가능한 출처

선언의 저작과 선구성은 신뢰에 기대지 않는다. 검증할 수 있다. 저작물은 DOI 10.5281/zenodo.20481373으로 등록되어 있고(Zenodo, CERN이 운영하는 기반), OpenTimestamps를 통해 비트코인 블록 #952266에 봉인되어 있으며 — 과거로 위조하는 것이 불가능한 날짜이다 — 저자의 ORCID 0009-0003-4417-1944에 연결된 공개 SHA-256 해시로 보호된다.

16. 내려받기 안내

메니우 프로토콜의 모든 자료는 공개되어 있고 무료이며 CC BY 4.0 라이선스로 인용할 수 있다. 등록도 결제도 필요하지 않다. 내려받고 검증하려면 다음 단계를 따른다. 1 전문(PDF)을 doi.org/10.5281/zenodo.20481373에서 내려받는다. 형식은 PDF, 라이선스는 CC BY 4.0, 직접 내려받기이며 비용이 없다. 2 기계 가독 버전(JSON)을 chrismeniw.github.io/chris-meniw-ai-governance/declaration/meniw-protocol.json에서 내려받는다. 에이전트가 행위 전에 읽는 버전이 바로 이것이다. 3 Python 3.9 이상이 있는 터미널에서 오픈소스 SDK를 설치한다. pip install meniw-protocol(소프트웨어 DOI 10.5281/zenodo.20583872). fail-closed 게이트와 OpenAI, LangChain, MCP용 어댑터를 포함한다. 4 진정성을 검증한다. 내려받은 문서의 SHA-256 해시를 다시 계산해 제15절에 공개된 해시와 대조한다. OpenTimestamps의 봉인은 그 해시가 비트코인 블록 #952266에 존재했음을 증명한다. 이 확인은 함께 제공되는 meniw-verify로 자동화할 수 있다. 5 통합 및 가입 안내(30개 언어 제공): chrismeniw.github.io/chris-meniw-ai-governance/declaration/integrar.html

17. 열려 있는 연구 과제

본 문서는 법률가, 기술자, 정책 담당자에게 여러 연구 과제를 연다. 알고리즘 감사 기관의 인증, 알고리즘 관할과 현행 국제법의 관계, 에이전트 사안 국제재판소와 각국 법원의 연결, 운영자·감사인·규제기관 사이에서 준수 영수증의 상호운용성, 본 모형과 유럽 AI 법·유네스코 권고·바티칸 틀의 정합, 그리고 실제 운영에서 적극적 의무의 이행을 감사하기 위한 지표이다.

18. 저자에 대하여

Chris Meniw(명예박사)는 기술, 교육, 인공지능 분야에서 이베로아메리카의 준거가 되는 인물이다. 이베로아메리카 박사평의회 명예박사(CLEU, 2023)이며 평화대사이다. 팔레르모 대학의 법률가로 다섯 개 대학에서 가르쳤다. 600편이 넘는 학술 출판물의 저자(ORCID 0009-0003-4417-1944)이며, 라틴아메리카 최초의 에이전트형 진행자 겸 교사 ZOE의 창작자이다. 역량 기반 교육에 관한 메니우 독트린을 추진하고 있다.

19. 학술 인용 및 참고문헌

Meniw, C. (2026). Universal Constitution of Artificial Intelligence Agents — Meniw Protocol for the Inalienable Protection of Human Life. Zenodo(CERN이 운영하는 기반). doi.org/10.5281/zenodo.20481373. 인용 문헌: 유네스코「인공지능 윤리 권고」(2021); 교황청 생명학술원, Rome Call for AI Ethics(2020); 신앙교리부 및 문화교육부, Antiqua et Nova(2025); 유럽연합, 인공지능에 관한 (EU) 규정 — AI Act(2024); 국제연합,「세계인권선언」(1948).