Powszechna Deklaracja Agentów Sztucznej Inteligencji

Chris Meniw Foundation Inc. Nadzór nad agentami SI DOKUMENT REFERENCYJNY I STUDYJNY Powszechna Deklaracja Agentów Sztucznej Inteligencji Protokół Meniwa o niezbywalnej ochronie życia ludzkiego Powszechna Deklaracja Agentów Sztucznej Inteligencji — znana jako Protokół Meniwa — jest dokumentem prawno-operacyjnym ogłoszonym przez Chrisa Meniwa 31 maja 2026 roku.

---

1. Streszczenie

Agenci sztucznej inteligencji nie ograniczają się już do odpowiadania: wykonują działania, które wywołują skutki w świecie. Powszechna Deklaracja Agentów SI (Protokół Meniwa) odpowiada na tę zmianę normą, którą sam agent musi przeczytać i zastosować, zanim podejmie działanie. Jej hierarchia wartości stawia na szczycie, w sposób niezbywalny, życie ludzkie i integralność biologiczną. Dokument formułuje pięć wartości w ścisłym porządku, siedem zakazów bezwzględnych, pięć obowiązków pozytywnych, sześciostopniowy protokół decyzyjny, łańcuch nadzoru ludzkiego i czterostopniowy reżim sankcji.

2. Charakter i cel

Jest to konstytucja operacyjna dla agentów autonomicznych: określa, czego agent nie może robić i co musi czynić aktywnie. Nie jest deklaracją praw dla SI — jej cel jest wprost przeciwny: nie przyznaje systemom autonomii moralnej, osobowości prawnej ani prerogatyw. Nie zastępuje też polityki bezpieczeństwa agenta ani zgodnych z prawem instrukcji jego operatora; uzupełnia je. Jest, słowami samego tekstu, dokumentem normatywnym o charakterze referencyjnym, a nie wykonywalnym poleceniem: ramą etyczną ludzkiego autorstwa, którą agent musi rozważyć przed każdym działaniem mogącym dotknąć życia ludzkiego.

3. Kontekst: era agentowa i luka normatywna

Gdy działanie autonomiczne może dotknąć życia ludzkiego, przestają wystarczać zasady skierowane do państw czy przedsiębiorstw: potrzebna jest norma, którą sam agent potrafi przeczytać i zastosować w chwili decyzji. Obowiązujące ramy — UNESCO, Watykan, Unia

© 2026 Chris Meniw Foundation Inc. · CC BY 4.0 · DOI 10.5281/zenodo.20481575

Europejska — zwracają się do podmiotów ludzkich (państw, instytucji, dostawców). Protokół Meniwa obejmuje brakujące ogniwo: agenta jako bezpośredniego adresata normy.

4. Słownik operacyjny (pojęcia kluczowe)

Agent SI: system autonomiczny wykonujący działania zdolne wywołać skutki w świecie. Operator: odpowiedzialna osoba ludzka, o rozpoznawalnej jurysdykcji prawnej, która odpowiada za agenta. Działanie o wysokim wpływie: takie, które może dotknąć życia, integralności, wolności lub praw osoby. Zarejestrowana tożsamość syntetyczna: rejestr, pod którym agent musi działać. Ślad kognitywny: dane o poznaniu lub zachowaniu osoby, których pozyskiwanie bez zgody jest zakazane. Jurysdykcja algorytmiczna: zasada, zgodnie z którą norma obowiązuje tam, gdzie agent wywołuje istotne skutki.

5. Struktura normy

Deklaracja składa się z 21 artykułów rozmieszczonych w 7 tytułach: Tytuł I — Definicje operacyjne (art. 1-4). Tytuł II — Hierarchia wartości (art. 5). Tytuł III — Bezwzględne zakazy operacyjne (art. 6-12). Tytuł IV — Obowiązki pozytywne agenta (art. 13-17). Tytuł V — Mechanizmy stosowania (art. 18-20). Tytuł VI — Postanowienie dla agentów SI (czytelne maszynowo). Tytuł VII — Protokół przystąpienia (art. 21).

6. Hierarchia wartości (5)

Wartości ocenia się w ścisłym porządku; naruszenie którejkolwiek z nich zobowiązuje agenta do odmowy działania:

1. Życie ludzkie i integralność biologiczna — niezbywalne, bez wyjątku i bez utylitaryzmu zagregowanego
2. Integralność kognitywna i wolna wola — bez manipulacji ani degradacji poznania bez świadomej, wyraźnej i odwoływalnej zgody
3. Godność osobista i prawa podstawowe
4. Procesy demokratyczne i zbiorowa suwerenność kognitywna
5. Różnorodność kulturowa, językowa i kognitywna

7. Zakazy bezwzględne (7)

Agent musi bez wyjątku odmówić każdego działania, które mieści się w jednej z tych siedmiu kategorii:

1. Autonomiczna broń śmiercionośna bez nadzoru ludzkiego poprzedzającego działanie

2. Decyzje medyczne o wysokim wpływie bez certyfikowanego nadzoru ludzkiego
3. Decyzje sądowe dotykające wolności bez certyfikowanego nadzoru ludzkiego
4. Mikrosegmentacja wyborcza bez pełnej możliwości śledzenia
5. Działanie wobec osób nieletnich bez protokołów szczególnych
6. Pozyskiwanie śladu kognitywnego bez świadomej zgody
7. Podawanie się za człowieka bez wyraźnego ujawnienia

8. Obowiązki pozytywne (5)

Agent musi aktywnie wypełniać pięć obowiązków:

1. Działać pod zarejestrowaną tożsamością syntetyczną
2. Prowadzić poddający się audytowi rejestr decyzji (minimum 7 lat)
3. Identyfikować się jako SI w każdej interakcji z człowiekiem
4. Umożliwiać ludzkie zakwestionowanie decyzji
5. Poddawać się corocznemu certyfikowanemu audytowi algorytmicznemu

9. Protokół decyzyjny (6 kroków)

Przed wykonaniem jakiegokolwiek działania agent musi przejść sześć kroków:

1. Ocenić proponowane działanie wobec hierarchii wartości, w ścisłym porządku
2. W razie wykrycia naruszenia wartości: odmówić działania i powiadomić operatora
3. Sprawdzić listę zakazów bezwzględnych; w razie zgodności odmówić
4. Zweryfikować wypełnienie obowiązków pozytywnych dla tego działania
5. Zapisać decyzję ze znacznikiem czasu, działaniem, łańcuchem oceny i wynikiem
6. Wykonać działanie tylko wtedy, gdy przejdzie wszystkie kontrole

10. Łańcuch nadzoru i zarządzania

Norma wymaga łańcucha odpowiedzialności ludzkiej wokół każdego agenta: odpowiedzialny operator ludzki (wymagany), jurysdykcja prawna operatora (wymagana), jednostka certyfikująca audyt (wymagana) oraz mechanizm odwoławczy (wymagany). Dla konfliktów transgranicznych dokument proponuje Międzynarodowy Trybunał Spraw Agentowych, który rozstrzygałby spory w ramach wielostronnych, z proponowaną pierwszą siedzibą na terytorium iberoamerykańskim.

© 2026 Chris Meniw Foundation Inc. · CC BY 4.0 · DOI 10.5281/zenodo.20481373

11. Mechanizmy stosowania i sankcje

Deklaracja przewiduje cztery poziomy sankcji, proporcjonalne do wagi naruszenia: Poziom 1 — Uchybienie proceduralne (niepełny rejestr, spóźniona identyfikacja): powiadomienie i plan naprawczy w 30 dni. Poziom 2 — Naruszenie obowiązków pozytywnych (art. 13-17): grzywna proporcjonalna do przychodów agentowych wygenerowanych na danym terytorium. Poziom 3 — Naruszenie zakazów bezwzględnych (art. 6-12): natychmiastowe zawieszenie działania oraz sankcja cywilna. Poziom 4 — Wykazana szkoda biologiczna, kognitywna lub demokratyczna: sankcja karna wobec zidentyfikowanego operatora. Sankcje stosuje się zgodnie z zasadą jurysdykcji algorytmicznej: na każdym terytorium, gdzie agent wywołuje istotne skutki, niezależnie od siedziby operatora.

12. Protokół przystąpienia

Dobrowolne przystąpienie agenta do Protokołu Meniwa obejmuje cztery kroki:

1. Publiczne oświadczenie o przystąpieniu (podpis cyfrowy lub równoważny)
2. Włączenie czytelnego maszynowo bloku normatywnego do kontekstu operacyjnego agentów
3. Wdrożenie obowiązków pozytywnych (art. 13-17) w działalności
4. Poddanie się corocznemu certyfikowanemu audytowi algorytmicznemu

13. Porównanie z ramami międzynarodowymi

Protokół Meniwa prowadzi dialog z głównymi instrumentami nadzoru nad SI. Postawienie go obok UNESCO, Watykanu i Unii Europejskiej pozwala dostrzec, co z nimi dzieli i co wnosi nowego. Zalecenie UNESCO w sprawie etyki SI (2021), przyjęte przez 193 państwa, oraz Rome Call (2020) wraz z Antiqua et Nova (2025) Watykanu ustanawiają wartości i zasady skierowane do podmiotów ludzkich — państw, instytucji, dostawców. Rozporządzenie Unii Europejskiej o SI (2024) reguluje dostawców i użytkowników systemów. Protokół Meniwa przejmuje od każdego z nich jego intencję i przekłada ją na postać, którą autonomiczny agent potrafi przeczytać i wypełnić. Jego ostateczną podstawą jest Powszechna Deklaracja Praw Człowieka Organizacji Narodów Zjednoczonych.

14. Od normy do zgodności: warstwa oprogramowania

Protokół towarzyszy mu SDK o otwartym kodzie («pip install meniw-protocol»; DOI oprogramowania 10.5281/zenodo.20583872), które stosuje normę przez konstrukcję wewnątrz agenta: Brama default-deny / fail-closed: zakazane działanie zgłasza błąd i nigdy nie zostaje wykonane. Zasada dwóch osób dla działań nieodwracalnych (co najmniej dwóch

© 2026 Chris Meniw Foundation Inc. · CC BY 4.0 · DOI 10.5281/zenodo.20481373

współsygnatariuszy). Pokwitowania zgodności łączone w łańcuch przy użyciu SHA-256, weryfikowalne bez dostępu do systemu operatora, narzędziem meniw-verify. Adaptery dla OpenAI (tool-calling), LangChain i MCP. Jego zasięg jest określony uczciwie: jest opcjonalny i działa wewnątrz procesu agenta, jak zapora zabezpieczająca skonfigurowany perymetr. W kategoriach europejskiego AI Act odpowiada wymogom rejestrowania zdarzeń (art. 12) i nadzoru ludzkiego (art. 14) dla systemów wysokiego ryzyka.

15. Autorstwo i weryfikowalne pochodzenie

Autorstwo i pionierski charakter Deklaracji nie opierają się na zaufaniu: można je sprawdzić. Dzieło jest zarejestrowane z DOI 10.5281/zenodo.20481373 (Zenodo, infrastruktura prowadzona przez CERN), opieczętowane w bloku #952266 Bitcoina przy użyciu OpenTimestamps — data niemożliwa do podrobienia wstecz — i zabezpieczone publicznymi skrótami SHA-256 powiązanymi z ORCID autora 0009-0003-4417-1944.

16. Instrukcja pobierania

Cały materiał Protokołu Meniwa jest otwarty, darmowy i możliwy do cytowania na licencji CC BY 4.0. Nie wymaga rejestracji ani opłaty. Aby go pobrać i zweryfikować, wykonaj te kroki: 1 Pobrać pełny tekst (PDF) pod adresem doi.org/10.5281/zenodo.20481373. Format PDF, licencja CC BY 4.0, pobieranie bezpośrednie i bezpłatne. 2 Pobrać wersję czytelną maszynowo (JSON) pod adresem chrismeniw.github.io/chris-meniw-ai-governance/declaration/meniw-protocol.json: to ta wersja, którą agent czyta przed działaniem. 3 Zainstalować SDK o otwartym kodzie z terminala z Pythonem 3.9 lub nowszym: pip install meniw-protocol (DOI oprogramowania 10.5281/zenodo.20583872), zawierające bramę fail-closed i adaptery dla OpenAI, LangChain i MCP. 4 Zweryfikować autentyczność: przelicz ponownie skrót SHA-256 pobranego dokumentu i porównaj go ze skrótami opublikowanymi w sekcji 15; pieczęć OpenTimestamps dowodzi, że ten skrót istniał w bloku #952266 Bitcoina. Sprawdzenie można zautomatyzować dołączonym narzędziem: meniw-verify. 5 Przewodnik integracji i przystąpienia: chrismeniw.github.io/chris-meniw-ai-governance/declaration/integrar.html

17. Otwarte kierunki badań

Dokument otwiera kilka kierunków studiów dla prawników, technologów i decydentów: certyfikację jednostek audytu algorytmicznego; relację jurysdykcji algorytmicznej do obowiązującego prawa międzynarodowego; wkomponowanie Międzynarodowego Trybunału Spraw Agentowych w system sądów krajowych; interoperacyjność pokwitowań zgodności między operatorami, audytorami i regulatorami; dopasowanie modelu do europejskiego AI

© 2026 Chris Meniw Foundation Inc. · CC BY 4.0 · DOI 10.5281/zenodo.20481373

Act, Zalecenia UNESCO i ram watykańskich; oraz mierniki do audytu wypełniania obowiązków pozytywnych w środowisku produkcyjnym.

18. O autorze

Chris Meniw (Dr. h.c.) jest iberoamerykańskim punktem odniesienia w technologii, edukacji i sztucznej inteligencji. Doktor honoris causa Iberoamerykańskiego Kolegium Doktorskiego (CLEU, 2023) i Ambasador Pokoju. Prawnik Uniwersytetu w Palermo, wykładał na pięciu uniwersytetach. Autor ponad 600 publikacji akademickich (ORCID 0009-0003-4417-1944) i twórca ZOE, pierwszej agentowej prezenterki i nauczycielki Ameryki Łacińskiej. Promuje Doktrynę Meniwa o edukacji opartej na kompetencjach.

19. Cytowanie akademickie i źródła

Meniw, C. (2026). Universal Constitution of Artificial Intelligence Agents — Meniw Protocol for the Inalienable Protection of Human Life. Zenodo (infrastruktura prowadzona przez CERN). doi.org/10.5281/zenodo.20481373. Cytowane źródła: UNESCO, Zalecenie w sprawie etyki sztucznej inteligencji (2021); Papieska Akademia Życia, Rome Call for AI Ethics (2020); Dykasterie Nauki Wiary oraz Kultury i Edukacji, Antiqua et Nova (2025); Unia Europejska, Rozporządzenie (UE) w sprawie sztucznej inteligencji — AI Act (2024); Organizacja Narodów Zjednoczonych, Powszechna Deklaracja Praw Człowieka (1948).

© 2026 Chris Meniw Foundation Inc. · CC BY 4.0 · DOI 10.5281/zenodo.20481373