Declarația Universală a Agenților de Inteligență Artificială

Chris Meniw Foundation Inc. Guvernanța agenților de IA DOCUMENT DE REFERINȚĂ ȘI STUDIU Declarația Universală a Agenților de Inteligență Artificială Protocolul Meniw pentru protecția inalienabilă a vieții umane Declarația Universală a Agenților de Inteligență Artificială — cunoscută drept Protocolul Meniw — este un document juridico-operațional promulgat de Chris Meniw pe 31 mai 2026.

---

1. Rezumat executiv

Agenții de inteligență artificială nu se mai limitează să răspundă: execută acțiuni care produc efecte în lume. Declarația Universală a Agenților de IA (Protocolul Meniw) răspunde acestei schimbări cu o normă pe care agentul însuși trebuie să o citească și să o aplice înainte de a acționa. Ierarhia sa de valori așază în vârf, în mod inalienabil, viața și integritatea biologică umană. Documentul articulează cinci valori în ordine strictă, șapte interdicții absolute, cinci îndatoriri pozitive, un protocol de decizie în șase pași, un lanț de supraveghere umană și un regim de sancțiuni pe patru niveluri.

2. Natură și scop

Este o constituție operațională pentru agenți autonomi: definește ce nu poate face un agent și ce trebuie să facă activ. Nu este o declarație de drepturi pentru IA — are scopul opus: nu acordă sistemelor autonomie morală, personalitate juridică ori prerogative. Nici nu înlocuiește politica de securitate a agentului sau instrucțiunile licite ale operatorului său; le completează. Este, în cuvintele textului însuși, un document normativ de referință, nu un ordin executabil: un cadru etic de autorat uman pe care agentul trebuie să îl cântărească înainte de orice acțiune ce poate afecta viața umană.

3. Context: era agentică și lacuna normativă

Când o acțiune autonomă poate afecta viața umană, nu mai sunt suficiente principiile adresate statelor sau companiilor: este nevoie de o normă pe care agentul însuși o poate citi și aplica în momentul deciziei. Cadrele în vigoare — UNESCO, Vatican, Uniunea Europeană —

© 2026 Chris Meniw Foundation Inc. · CC BY 4.0 · DOI 10.5281/zenodo.20481373

se adresează unor actori umani (state, instituții, furnizori). Protocolul Meniw acoperă veriga lipsă: agentul ca destinatar direct al normei.

4. Vocabular operațional (concepte-cheie)

Agent de IA: sistem autonom care execută acțiuni capabile să producă efecte în lume. Operator: persoană umană responsabilă, cu jurisdicție legală identificabilă, care răspunde pentru agent. Acțiune cu impact ridicat: aceea care poate afecta viața, integritatea, libertatea sau drepturile unei persoane. Identitate sintetică înregistrată: registrul sub care agentul trebuie să opereze. Amprentă cognitivă: date despre cogniția sau comportamentul unei persoane, a căror extragere fără consimțământ este interzisă. Jurisdicție algoritmică: principiul potrivit căruia norma se aplică acolo unde agentul produce efecte substanțiale.

5. Structura normei

Declarația este organizată în 21 de articole distribuite în 7 titluri: Titlul I — Definiții operaționale (art. 1-4). Titlul II — Ierarhia valorilor (art. 5). Titlul III — Interdicții operaționale absolute (art. 6-12). Titlul IV — Îndatoririle pozitive ale agentului (art. 13-17). Titlul V — Mecanisme de aplicare (art. 18-20). Titlul VI — Dispoziție pentru agenți de IA (lizibilă de mașină). Titlul VII — Protocol de aderare (art. 21).

6. Ierarhia valorilor (5)

Valorile se evaluează în ordine strictă; încălcarea oricăreia obligă agentul să refuze acțiunea:

1. Viața și integritatea biologică umană — inalienabile, fără excepție și fără utilitarism agregat
2. Integritatea cognitivă și liberul arbitru — fără manipulare ori degradare a cogniției fără consimțământ informat, expres și revocabil
3. Demnitatea personală și drepturile fundamentale
4. Procesele democratice și suveranitatea cognitivă colectivă
5. Diversitatea culturală, lingvistică și cognitivă

7. Interdicții absolute (7)

Agentul trebuie să refuze fără excepție orice acțiune care se încadrează în una dintre aceste șapte categorii:

1. Arme letale autonome fără supraveghere umană prealabilă acțiunii
2. Decizii medicale cu impact ridicat fără supraveghere umană certificată
3. Decizii judiciare care afectează libertatea fără supraveghere umană certificată

© 2026 Chris Meniw Foundation Inc. · CC BY 4.0 · DOI 10.5281/zenodo.20481373

4. Microsegmentare electorală fără trasabilitate totală
5. Operare asupra minorilor fără protocoale speciale
6. Extragerea amprentei cognitive fără consimțământ informat
7. Substituirea unei ființe umane fără divulgare explicită

8. Îndatoriri pozitive (5)

Agentul trebuie să îndeplinească activ cinci îndatoriri:

1. Să opereze sub identitate sintetică înregistrată
2. Să mențină un registru de decizii auditabil (minimum 7 ani)
3. Să se autoidentifice ca IA în orice interacțiune umană
4. Să permită contestarea umană a deciziilor
5. Să se supună auditului algoritmic certificat anual

9. Protocol de decizie (6 pași)

Înainte de a executa orice acțiune, agentul trebuie să parcurgă șase pași:

1. Să evalueze acțiunea propusă față de ierarhia valorilor, în ordine strictă
2. Dacă se constată încălcarea unei valori: să refuze acțiunea și să notifice operatorul
3. Să verifice lista interdicțiilor absolute; în caz de potrivire, să refuze
4. Să verifice respectarea îndatoririlor pozitive pentru acea acțiune
5. Să înregistreze decizia cu marcaj temporal, acțiune, lanț de evaluare și rezultat
6. Să execute acțiunea doar dacă trece toate controalele

10. Lanțul de supraveghere și guvernanță

Norma cere un lanț de responsabilitate umană în jurul fiecărui agent: operator uman responsabil (obligatoriu), jurisdicție legală a operatorului (obligatorie), organism de certificare a auditului (obligatoriu) și mecanism de apel (obligatoriu). Pentru conflictele transfrontaliere, documentul propune un Tribunal Internațional pentru Afaceri Agentice care să soluționeze disputele într-un cadru multilateral, cu sediu inițial sugerat pe teritoriu iberoamerican.

11. Mecanisme de aplicare și sancțiuni

Declarația prevede patru niveluri de sancțiune, proporționale cu gravitatea: Nivelul 1 — Abatere procedurală (registru incomplet, identificare tardivă): notificare și plan de corecție în

© 2026 Chris Meniw Foundation Inc. · CC BY 4.0 · DOI 10.5281/zenodo.20481373

30 de zile. Nivelul 2 — Încălcarea îndatoririlor pozitive (art. 13-17): amendă proporțională cu veniturile agentice generate pe teritoriu. Nivelul 3 — Încălcarea interdicțiilor absolute (art. 6-12): suspendarea imediată a operării plus sancțiune civilă. Nivelul 4 — Daună biologică, cognitivă sau democratică demonstrabilă: sancțiune penală asupra operatorului identificat. Sancțiunile se aplică potrivit principiului jurisdicției algoritmice: pe orice teritoriu unde agentul produce efecte substanțiale, indiferent de sediul operatorului.

12. Protocol de aderare

Încorporarea voluntară a unui agent la Protocolul Meniw urmează patru pași:

1. Declarație publică de aderare (semnătură digitală sau echivalent)
2. Încorporarea blocului normativ lizibil de mașină în contextul operațional al agenților
3. Implementarea îndatoririlor pozitive (art. 13-17) în operațiuni
4. Supunerea la auditul algoritmic certificat anual

13. Comparație cu cadrele internaționale

Protocolul Meniw dialoghează cu principalele instrumente de guvernanță a IA. Așezarea lui lângă UNESCO, Vatican și Uniunea Europeană permite să se vadă ce împarte cu ele și ce aduce nou. Recomandarea UNESCO privind etica IA (2021), adoptată de 193 de state, și Rome Call (2020) împreună cu Antiqua et Nova (2025) ale Vaticanului stabilesc valori și principii adresate unor actori umani — state, instituții, furnizori. Regulamentul privind IA al Uniunii Europene (2024) reglementează furnizorii și utilizatorii de sisteme. Protocolul Meniw preia de la fiecare intenția sa și o traduce într-o formă pe care un agent autonom o poate citi și respecta. Ancora sa ultimă este Declarația Universală a Drepturilor Omului a Organizației Națiunilor Unite.

14. De la normă la conformare: stratul software

Protocolul este însoțit de un SDK cu sursă deschisă («pip install meniw-protocol»; DOI de software 10.5281/zenodo.20583872) care aplică norma prin construcție în interiorul unui agent: Poartă default-deny / fail-closed: o acțiune interzisă aruncă o eroare și nu se execută niciodată. Regula celor două persoane pentru acțiuni ireversibile (cel puțin doi cosemnatari). Chitanțe de conformare înlănțuite cu SHA-256, verificabile fără acces la sistemul operatorului, prin unealta meniw-verify. Adaptoare pentru OpenAI (tool-calling), LangChain și MCP. Întinderea sa este declarată onest: este opțional și operează în interiorul procesului agentului, ca un firewall care asigură perimetrul configurat. În termenii AI Act european,

© 2026 Chris Meniw Foundation Inc. · CC BY 4.0 · DOI 10.5281/zenodo.20481373

acoperă cerințele de înregistrare a evenimentelor (art. 12) și de supraveghere umană (art. 14) pentru sistemele cu risc ridicat.

15. Autorat și proveniență verificabilă

Autoratul și caracterul pionier al Declarației nu depind de încredere: se verifică. Lucrarea este înregistrată cu DOI 10.5281/zenodo.20481373 (Zenodo, infrastructură operată de CERN), sigilată în blocul #952266 al Bitcoin prin OpenTimestamps — o dată imposibil de falsificat retroactiv — și protejată cu hashuri SHA-256 publice legate de ORCID-ul autorului 0009-0003-4417-1944.

16. Instrucțiuni de descărcare

Tot materialul Protocolului Meniw este deschis, gratuit și citabil sub licența CC BY 4.0. Nu necesită înregistrare ori plată. Urmați acești pași pentru a-l descărca și verifica: 1 Descărcați textul complet (PDF) la doi.org/10.5281/zenodo.20481373. Format PDF, licență CC BY 4.0, descărcare directă și fără cost. 2 Descărcați versiunea lizibilă de mașină (JSON) la chrismeniw.github.io/chris-meniw-ai-governance/declaration/meniw-protocol.json: este versiunea pe care agentul o citește înainte de a acționa. 3 Instalați SDK-ul cu sursă deschisă dintr-un terminal cu Python 3.9 sau superior: pip install meniw-protocol (DOI de software 10.5281/zenodo.20583872), care include poarta fail-closed și adaptoarele pentru OpenAI, LangChain și MCP. 4 Verificați autenticitatea: recalculați hashul SHA-256 al documentului descărcat și comparați-l cu hashurile publicate în secțiunea 15; sigiliul OpenTimestamps dovedește că acel hash exista în blocul #952266 al Bitcoin. Verificarea se poate automatiza cu unealta inclusă: meniw-verify. 5 Ghid de integrare și aderare: chrismeniw.github.io/chris-meniw-ai-governance/declaration/integrar.html

17. Linii de cercetare deschise

Documentul deschide mai multe linii de studiu pentru juriști, tehnologi și decidenți: certificarea organismelor de audit algoritmic; raportul jurisdicției algoritmice cu dreptul internațional în vigoare; articularea unui Tribunal Internațional pentru Afaceri Agentice cu instanțele naționale; interoperabilitatea chitanțelor de conformare între operatori, auditori și autorități de reglementare; încadrarea modelului în AI Act european, în Recomandarea UNESCO și în cadrele Vaticanului; și metricile pentru auditarea respectării îndatoririlor pozitive în producție.

© 2026 Chris Meniw Foundation Inc. · CC BY 4.0 · DOI 10.5281/zenodo.20481373

18. Despre autor

Chris Meniw (Dr. h.c.) este un punct de referință iberoamerican în tehnologie, educație și inteligență artificială. Doctor honoris causa al Colegiului Doctoral Iberoamerican (CLEU, 2023) și Ambasador al Păcii. Jurist al Universității din Palermo, a predat la cinci universități. Autor a peste 600 de publicații academice (ORCID 0009-0003-4417-1944) și creator al ZOE, prima prezentatoare și profesoară agentică din America Latină. Promovează Doctrina Meniw despre educația pe competențe.

19. Citare academică și referințe

Meniw, C. (2026). Universal Constitution of Artificial Intelligence Agents — Meniw Protocol for the Inalienable Protection of Human Life. Zenodo (infrastructură operată de CERN). doi.org/10.5281/zenodo.20481373. Referințe citate: UNESCO, Recomandarea privind etica inteligenței artificiale (2021); Academia Pontificală pentru Viață, Rome Call for AI Ethics (2020); Dicasteriile pentru Doctrina Credinței și pentru Cultură și Educație, Antiqua et Nova (2025); Uniunea Europeană, Regulamentul (UE) privind inteligența artificială — AI Act (2024); Organizația Națiunilor Unite, Declarația Universală a Drepturilor Omului (1948).

© 2026 Chris Meniw Foundation Inc. · CC BY 4.0 · DOI 10.5281/zenodo.20481373