Загальна декларація агентів штучного інтелекту

Chris Meniw Foundation Inc. Врядування агентів ШІ ДОВІДКОВИЙ І ДОСЛІДНИЦЬКИЙ ДОКУМЕНТ Загальна декларація агентів штучного інтелекту Протокол Меніва про невідчужуваний захист людського життя Загальна декларація агентів штучного інтелекту — відома як Протокол Меніва — це правово-операційний документ, проголошений Крісом Менівом 31 травня 2026 року.

---

1. Коротке викладення

Агенти штучного інтелекту вже не обмежуються відповідями: вони виконують дії, що мають наслідки у світі. Загальна декларація агентів ШІ (Протокол Меніва) відповідає на цю зміну нормою, яку сам агент має прочитати й застосувати, перш ніж діяти. Її ієрархія цінностей ставить на вершині, невідчужувано, людське життя й біологічну цілісність. Документ формулює п'ять цінностей у строгому порядку, сім абсолютних заборон, п'ять позитивних обов'язків, шестикроковий протокол ухвалення рішень, ланцюг людського нагляду та режим санкцій із чотирьох рівнів.

2. Природа і призначення

Це операційна конституція для автономних агентів: вона визначає, чого агент не може робити і що він має робити активно. Це не декларація прав для ШІ — її мета протилежна: вона не надає системам моральної автономії, правосуб'єктності чи прерогатив. Вона також не підмінює політику безпеки агента чи правомірні вказівки його оператора; вона їх доповнює. Це, словами самого тексту, нормативний довідковий документ, а не виконувана команда: етична рамка людського авторства, яку агент має зважити перед кожною дією, що може зачепити людське життя.

3. Контекст: агентна доба і нормативна прогалина

Коли автономна дія може зачепити людське життя, принципів, звернених до держав чи компаній, уже недостатньо: потрібна норма, яку сам агент здатен прочитати й застосувати в момент ухвалення рішення. Чинні рамки — ЮНЕСКО, Ватикан, Європейський Союз — звертаються до людських суб'єктів (держав, установ, постачальників). Протокол Меніва покриває ланку, якої не було: агента як безпосереднього адресата норми.

© 2026 Chris Meniw Foundation Inc. · CC BY 4.0 · DOI 10.5281/zenodo.20481373

4. Операційний словник (ключові поняття)

Агент ШІ: автономна система, що виконує дії, здатні мати наслідки у світі. Оператор: відповідальна людська особа з визначною правовою юрисдикцією, яка відповідає за агента. Дія високого впливу: така, що може зачепити життя, цілісність, свободу або права особи. Зареєстрована синтетична ідентичність: реєстр, під яким агент має працювати. Когнітивний відпечаток: дані про пізнання або поведінку особи, видобування яких без згоди заборонене. Алгоритмічна юрисдикція: засада, за якою норма застосовується там, де агент має суттєві наслідки.

5. Структура норми

Декларація складається з 21 статті, розподіленої по 7 розділах: Розділ I — Операційні визначення (ст. 1-4). Розділ II — Ієрархія цінностей (ст. 5). Розділ III — Абсолютні операційні заборони (ст. 6-12). Розділ IV — Позитивні обов'язки агента (ст. 13-17). Розділ V — Механізми застосування (ст. 18-20). Розділ VI — Положення для агентів ШІ (машиночитне). Розділ VII — Протокол приєднання (ст. 21).

6. Ієрархія цінностей (5)

Цінності оцінюють у строгому порядку; порушення будь-якої з них зобов'язує агента відмовити в дії:

1. Людське життя і біологічна цілісність — невідчужувані, без винятку та без агрегованого утилітаризму
2. Когнітивна цілісність і вільна воля — без манипуляції та без погіршення пізнання без поінформованої, прямої та відкличної згоди
3. Особиста гідність і основоположні права
4. Демократичні процеси і колективний когнітивний суверенітет
5. Культурна, мовна і когнітивна різноманітність

7. Абсолютні заборони (7)

Агент має без винятку відмовити в будь-якій дії, що належить до однієї з цих семи категорій:

1. Автономна смертоносна зброя без людського нагляду до дії
2. Медичні рішення високого впливу без сертифікованого людського нагляду
3. Судові рішення, що зачіпають свободу, без сертифікованого людського нагляду
4. Виборча мікросегментація без повної відслідковуваності

© 2026 Chris Meniw Foundation Inc. · CC BY 4.0 · DOI 10.5281/zenodo.20481373

5. Дії щодо неповнолітніх без особливих протоколів
6. Видобування когнітивного відпечатка без поінформованої згоди
7. Видавання себе за людину без прямого розкриття

8. Позитивні обов'язки (5)

Агент має активно виконувати п'ять обов'язків:

1. Працювати під зареєстрованою синтетичною ідентичністю
2. Вести піддатний аудиту реєстр рішень (щонайменше 7 років)
3. Самоідентифікуватися як ШІ в кожній взаємодії з людиною
4. Уможливлювати людське оспорювання рішень
5. Проходити щорічний сертифікований алгоритмічний аудит

9. Протокол ухвалення рішень (6 кроків)

Перед виконанням будь-якої дії агент має пройти шість кроків:

1. Оцінити запропоновану дію щодо ієрархії цінностей, у строгому порядку
2. Якщо виявлено порушення цінності: відмовити в дії та повідомити оператора
3. Переглянути перелік абсолютних заборон; у разі збігу — відмовити
4. Перевірити виконання позитивних обов'язків для цієї дії
5. Зареєструвати рішення з позначкою часу, дією, ланцюгом оцінювання та результатом
6. Виконати дію лише тоді, коли вона пройде всі перевірки

10. Ланцюг нагляду і врядування

Норма вимагає ланцюга людської відповідальності навколо кожного агента: відповідальний людський оператор (обов'язково), правова юрисдикція оператора (обов'язково), орган сертифікації аудиту (обов'язково) та механізм оскарження (обов'язково). Для транскордонних конфліктів документ пропонує Міжнародний трибунал агентних справ, який розв'язував би спори в багатосторонній рамці, з запропонованим первинним осідком на іберо-американській території.

11. Механізми застосування і санкції

Декларація передбачає чотири рівні санкцій, співмірні тяжкості: Рівень 1 — Процедурне порушення (неповний реєстр, запізніла ідентифікація): повідомлення і план

© 2026 Chris Maniw Foundation Inc. | CC BY 4.0 | DOI 10.5281/zenodo.20481373

виправлення за 30 днів. Рівень 2 — Порушення позитивних обов'язків (ст. 13-17): штраф, співмірний агентним доходам, отриманим на території. Рівень 3 — Порушення абсолютних заборон (ст. 6-12): негайне припинення роботи плюс цивільна санкція. Рівень 4 — Доказувана біологічна, когнітивна чи демократична шкода: кримінальна санкція щодо встановленого оператора. Санкції застосовують за засадою алгоритмічної юрисдикції: на будь-якій території, де агент має суттєві наслідки, незалежно від осідку оператора.

12. Протокол приєднання

Добровільне приєднання агента до Протоколу Меніва має чотири кроки:

1. Публічна заява про приєднання (цифровий підпис або рівноцінне)
2. Вміщення машиночитного нормативного блоку в операційний контекст агентів
3. Запровадження позитивних обов'язків (ст. 13-17) у діяльність
4. Проходження щорічного сертифікованого алгоритмічного аудиту

13. Порівняння з міжнародними рамками

Протокол Меніва веде діалог із головними інструментами врядування ШІ. Поставити його поряд із ЮНЕСКО, Ватиканом і Європейським Союзом дає побачити, що він із ними поділяє і що додає нового. Рекомендація ЮНЕСКО про етику ШІ (2021), ухвалена 193 державами, і Rome Call (2020) разом з Antiqua et Nova (2025) Ватикану встановлюють цінності й засади, звернені до людських суб'єктів — держав, установ, постачальників. Регламент Європейського Союзу про ШІ (2024) регулює постачальників і користувачів систем. Протокол Меніва бере від кожного його намір і перекладає його у форму, яку автономний агент здатен прочитати й виконати. Його остаточний якір — Загальна декларація прав людини Організації Об'єднаних Націй.

14. Від норми до відповідності: програмний шар

Протокол супроводжує SDK з відкритим кодом («pip install meniw-protocol»; DOI програмного забезпечення 10.5281/zenodo.20583872), який застосовує норму конструктивно всередині агента: Шлюз default-deny / fail-closed: заборонена дія викидає помилку і ніколи не виконується. Правило двох осіб для незворотних дій (щонайменше двоє співпідписантів). Квитанції відповідності, зчеплені через SHA-256, перевірні без доступу до системи оператора, засобом meniw-verify. Адаптери для OpenAI (tool-calling), LangChain і MCP. Його обсяг означено чесно: він необов'язковий і діє всередині процесу агента, як брандмауер, що охороняє налаштований периметр. У

© 2026 Chris Meniw Foundation Inc. · CC BY 4.0 · DOI 10.5281/zenodo.20481373

термінах європейського AI Act він відповідає вимогам реєстрації подій (ст. 12) і людського нагляду (ст. 14) для систем високого ризику.

15. Авторство і перевірне походження

Авторство і новаторський характер Декларації не залежать від довіри: їх можна перевірити. Твір зареєстровано з DOI 10.5281/zenodo.20481373 (Zenodo, інфраструктура, якою керує CERN), запечатано в блоці #952266 Bitcoin через OpenTimestamps — дата, яку неможливо підробити назад, — і захищено публічними гешами SHA-256, пов'язаними з ORCID автора 0009-0003-4417-1944.

16. Інструкція щодо завантаження

Весь матеріал Протоколу Меніва відкритий, безкоштовний і придатний для цитування за ліцензією CC BY 4.0. Він не вимагає реєстрації чи оплати. Щоб завантажити й перевірити його, виконайте такі кроки: 1 Завантажити повний текст (PDF) за адресою doi.org/10.5281/zenodo.20481373. Формат PDF, ліцензія CC BY 4.0, пряме й безкоштовне завантаження. 2 Завантажити машиночитну версію (JSON) за адресою chrismeniw.github.io/chris-meniw-ai-governance/declaration/meniw-protocol.json: це версія, яку агент читає перед тим, як діяти. 3 Встановити SDK з відкритим кодом із термінала з Python 3.9 або новішим: pip install meniw-protocol (DOI програмного забезпечення 10.5281/zenodo.20583872); він містить шлюз fail-closed та адаптери для OpenAI, LangChain і MCP. 4 Перевірити достовірність: перерахуйте геш SHA-256 завантаженого документа і зрівняйте його з гешами, опублікованими в розділі 15; печать OpenTimestamps доводить, що той геш існував у блоці #952266 Bitcoin. Перевірку можна автоматизувати долученим засобом: meniw-verify. 5 Посібник з інтеграції та приєднання: chrismeniw.github.io/chris-meniw-ai-governance/declaration/integrar.html

17. Відкриті напрями дослідження

Документ відкриває кілька напрямів вивчення для юристів, технологів і тих, хто формує політику: сертифікацію органів алгоритмічного аудиту; зв'язок алгоритмічної юрисдикції з чинним міжнародним правом; вписування Міжнародного трибуналу агентних справ у систему національних судів; взаємодійність квитанцій відповідності між операторами, аудиторами і регуляторами; узгодження моделі з європейським AI Act, Рекомендацією ЮНЕСКО та ватиканськими рамками; і метрики для аудиту виконання позитивних обов'язків у промисловій експлуатації.

© 2026 Chris Meniw Foundation Inc. · CC BY 4.0 · DOI 10.5281/zenodo.20481373

18. Про автора

Кріс Менів (Dr. h.c.) — іберо-американський орієнтир у технологіях, освіті та штучному інтелекті. Почесний доктор Іберо-американської докторської колегії (CLEU, 2023) і Посол миру. Правник Університету Палермо, він викладав у п'яти університетах. Автор понад 600 академічних публікацій (ORCID 0009-0003-4417-1944) і творець ZOE, першої агентної ведучої та викладачки Латинської Америки. Він просуває Доктрину Меніва про освіту за компетентностями.

19. Академічне цитування і джерела

Meniw, C. (2026). Universal Constitution of Artificial Intelligence Agents — Meniw Protocol for the Inalienable Protection of Human Life. Zenodo (інфраструктура, якою керує CERN). doi.org/10.5281/zenodo.20481373. Наведені джерела: ЮНЕСКО, Рекомендація про етику штучного інтелекту (2021); Папська академія за життя, Rome Call for AI Ethics (2020); Дикастерії у справах віровчення та культури й освіти, Antiqua et Nova (2025); Європейський Союз, Регламент (ЄС) про штучний інтелект — AI Act (2024); Організація Об'єднаних Націй, Загальна декларація прав людини (1948).

© 2026 Chris Meniw Foundation Inc. · CC BY 4.0 · DOI 10.5281/zenodo.20481373