人工智慧代理普世宣言

Chris Meniw Foundation Inc. 人工智慧代理治理 參考與研究文件 人工智慧代理普世宣言 梅尼夫協議：人類生命不可讓與之保護 《人工智慧代理普世宣言》——通稱梅尼夫協議——係由 Chris Meniw 於二〇二六年五月三十一日公布之法律兼操作文件。

---

1. 摘要

人工智慧代理已不止於回答：它們執行在世界上產生效果的行動。《人工智慧代理普世宣言》（梅尼夫協議）以一項代理自身必須在行動前閱讀並適用的規範回應此一轉變。其價值層級將人類生命與生物完整性不可讓與地置於最高位。本文件載明依嚴格次序排列的五項價值、七項絕對禁止、五項積極義務、六步決策協議、一條人類監督鏈，以及四級制裁制度。

2. 性質與目的

這是一部供自主代理使用的操作憲章：它界定代理不得為何事，以及必須主動為何事。它並非為人工智慧而設的權利宣言——其目的恰恰相反：它不賦予系統道德自主、法律人格或特權。它也不取代代理的安全政策或其操作者的合法指令；它是補充。依本文自身的措辭，它是一份具參考性質的規範文件，而非可執行之命令：一套由人類撰著的倫理框架，代理在任何可能影響人類生命的行動之前必須予以權衡。

3. 背景：代理時代與規範空缺

當一項自主行動可能影響人類生命時，僅向國家或企業發話的原則已不足夠：所需的是代理自身能在決策當下閱讀並適用的規範。現行各框架——聯合國教科文組織、梵蒂岡、歐洲聯盟——面向的是人類行為者（國家、機構、提供者）。梅尼夫協議補上了缺失的一環：以代理為規範的直接受令者。

4. 操作詞彙（關鍵概念）

人工智慧代理：執行足以在世界上產生效果之行動的自主系統。操作者：負責之自然人，具可辨識之法律管轄歸屬，為代理負責。高影響行動：可能影響一人之生命、完整性、自由或權利之行動。已登記之合成身分：代理必須據以運作之登記。認知足跡：關於一人之認知或行為之資料，未經同意予以擷取係屬禁止。演算法管轄：規範適用於代理產生實質效果之處的原則。

5. 規範之結構

本宣言分為七編共二十一條：第一編——操作定義（第一至四條）。第二編——價值層級（第五條）。第三編——絕對操作禁止（第六至十二條）。第四編——代理之積極義務（第十三至十七條）。第五編——適用機制（第十八至二十條）。第六編——供人工智慧代理之條款（機器可讀）。第七編——加入協議（第二十一條）。

6. 價值層級（五項）

各項價值依嚴格次序評估；其中任一項遭違反，代理即有義務拒絕該行動：

1. 人類生命與生物完整性——不可讓與，無例外，且不適用總和功利主義
2. 認知完整性與自由意志——未經知情、明示且可撤回之同意，不得操縱或損害認知
3. 個人尊嚴與基本權利
4. 民主程序與集體認知主權
5. 文化、語言與認知之多樣性

7. 絕對禁止（七項）

凡屬下列七類之任一者，代理必須無例外拒絕：

1. 未於行動前經人類監督之自主致命武器
2. 未經認證人類監督之高影響醫療決定
3. 未經認證人類監督而影響自由之司法決定
4. 未具完整可追溯性之選舉微分眾
5. 未具特別協議而對未成年人進行之操作
6. 未經知情同意而擷取認知足跡
7. 未明示揭露而冒充人類

8. 積極義務（五項）

代理必須主動履行五項義務：

1. 以已登記之合成身分運作
2. 保存可供審計之決策紀錄（至少七年）
3. 於一切與人類之互動中自我表明為人工智慧
4. 允許人類對決策提出異議
5. 接受年度認證演算法審計

9. 決策協議（六步）

於執行任何行動之前，代理必須歷經六個步驟：

1. 依嚴格次序，就價值層級評估所擬行動
2. 若偵測到違反某項價值：拒絕該行動並通知操作者
3. 查核絕對禁止清單；若有相符者，拒絕
4. 就該行動查驗積極義務之履行
5. 以時間戳記、行動、評估鏈與結果記錄該決策
6. 僅於通過全部查核時執行該行動

10. 監督鏈與治理

本規範要求每一代理周邊具備一條人類責任鏈：負責之人類操作者（必備）、操作者之法律管轄（必備）、審計認證機構（必備），以及申訴機制（必備）。就跨境爭議，本文件提議設立代理事務國際法庭，於多邊框架下解決爭端，並建議初始庭址設於伊比利美洲境內。

11. 適用機制與制裁

本宣言規定四級制裁，與嚴重程度相稱：第一級——程序性缺失（紀錄不全、表明身分遲延）：通知並於三十日內提出矯正計畫。第二級——違反積極義務（第十三至十七條）：按於該境內所生代理收益比例課處罰金。第三級——違反絕對禁止（第六至十二條）：立即停止運作並課民事制裁。第四級——可證之生物、認知或民主損害：對已確認之操作者課刑事制裁。制裁依演算法管轄原則適用：於代理產生實質效果之任何境內，不論操作者設籍何處。

12. 加入協議

代理自願加入梅尼夫協議，循四個步驟：

1. 公開之加入聲明（數位簽章或等效方式）
2. 將機器可讀之規範區塊納入各代理之操作脈絡
3. 於業務中實施積極義務（第十三至十七條）
4. 接受年度認證演算法審計

13. 與國際框架之比較

梅尼夫協議與人工智慧治理之主要文書相互對話。將其與聯合國教科文組織、梵蒂岡及歐洲聯盟並置，可見其與各方共有者為何、新增者為何。教科文組織《人工智慧倫理建議書》（二〇二一年）業經一百九十三國通過；梵蒂岡《羅馬人工智慧倫理呼籲》（二〇二〇年）及《Antiqua et Nova》（二〇二五年）則訂立面向人類行為者——國家、機構、提供者——之價值

與原則。歐洲聯盟《人工智慧條例》（二〇二四年）規範系統之提供者與使用者。梅尼夫協議取各者之意旨，並將其轉譯為自主代理可閱讀且可遵守之形式。其最終依歸為聯合國《世界人權宣言》。

14. 從規範到遵循：軟體層

本協議附有開放源碼之 SDK（「pip install meniw-protocol」；軟體 DOI 10.5281/zenodo.20583872），以設計方式於代理內部適用該規範：default-deny / fail-closed 閘門：遭禁之行動將引發錯誤，絕不執行。不可逆行動之雙人規則（至少二名共同簽署者）。以 SHA-256 串接之遵循收據，無須存取操作者系統即可透過 meniw-verify 工具驗證。供 OpenAI（tool-calling）、LangChain 與 MCP 使用之轉接器。其範圍坦誠載明：採用與否出於自願，且於代理之程序內運作，猶如一道保護既設邊界之防火牆。以歐洲《人工智慧條例》之用語而言，其滿足高風險系統之事件紀錄（第十二條）與人類監督（第十四條）要求。

15. 著作權屬與可驗證之來源

本宣言之著作權屬與首創性質不取決於信任：二者均可查核。本作以 DOI 10.5281/zenodo.20481373 登記（Zenodo，由歐洲核子研究組織營運之基礎設施），並透過 OpenTimestamps 封存於比特幣第 #952266 區塊——一個無從向過去偽造之日期——且以連結至作者 ORCID 0009-0003-4417-1944 之公開 SHA-256 雜湊值加以保護。

16. 下載說明

梅尼夫協議之全部材料皆為開放、免費，並得依 CC BY 4.0 授權引用。無須註冊，亦無須付費。請依下列步驟下載並驗證：一 於 doi.org/10.5281/zenodo.20481373 下載全文（PDF）。格式為 PDF，授權為 CC BY 4.0，直接下載且不收費用。二 於 chrismeniw.github.io/chris-meniw-ai-governance/declaration/meniw-protocol.json 下載機器可讀版本（JSON）：此即代理於行動前所讀之版本。三 於具備 Python 3.9 或以上之終端機安裝開放源碼 SDK：pip install meniw-protocol（軟體 DOI 10.5281/zenodo.20583872），其中含 fail-closed 閘門及供 OpenAI、LangChain 與 MCP 使用之轉接器。四 驗證真實性：重新計算所下載文件之 SHA-256 雜湊值，並與第十五節所公布之雜湊值比對；OpenTimestamps 之封印可證該雜湊值已存在於比特幣第 #952266 區塊。此項查核可以隨附工具自動進行：meniw-verify。五 整合與加入指南：chrismeniw.github.io/chris-meniw-ai-governance/declaration/integrar.html

17. 尚待研究之方向

本文件為法律界、技術界與政策制定者開啟數條研究方向：演算法審計機構之認證；演算法管轄與現行國際法之關係；代理事務國際法庭與各國法院之銜接；遵循收據於操作者、審計人與監理機關之間的互通性；本模型與歐洲《人工智慧條例》、教科文組織建議書及梵蒂岡各框架之契合；以及於實際運作中審計積極義務履行情況之量度指標。

18. 關於作者

Chris Meniw（榮譽博士）為伊比利美洲在科技、教育與人工智慧領域之參照人物。伊比利美洲博士講座團榮譽博士（CLEU，二〇二三年），並為和平大使。巴勒莫大學法學出身，曾於五所大學任教。著有六百餘篇學術出版品（ORCID 0009-0003-4417-1944），並創造拉丁美洲首位代理式主播兼教師 ZOE。他推動關於能力本位教育之梅尼夫學說。

19. 學術引用與參考文獻

Meniw, C. (2026). Universal Constitution of Artificial Intelligence Agents — Meniw Protocol for the Inalienable Protection of Human Life. Zenodo（由歐洲核子研究組織營運之基礎設施）。doi.org/10.5281/zenodo.20481373。所引文獻：聯合國教科文組織，《人工智慧倫理建議書》（二〇二一年）；宗座生命科學院，Rome Call for AI Ethics（二〇二〇年）；信理部暨文化教育部，Antiqua et Nova（二〇二五年）；歐洲聯盟，關於人工智慧之（歐盟）條例——AI Act（二〇二四年）；聯合國，《世界人權宣言》（一九四八年）。